



MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR
DE LA RECHERCHE SCIENTIFIQUE ET DE L'INNOVATION
UNIVERSITÉ SULTAN MOULAY SLIMANE
ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES
DE KHOURIBGA



Rapport de Projet de Fin d'Études

Filière : Informatique et Ingénierie des Données



Réalisé par :
Taha FERHAN

Modélisation probabiliste du potentiel commercial pour l'aide à la décision d'implantation

Effectué au sein de



Encadrant Externe :

M. Badreddine BENDAMI

Encadrant Interne :

Pr. Abderrahim AZOUANI

Membres du jury

Pr. Abdelmajid DARGHAM	Président
Pr. Loubna RABHI	Examinatrice

Année Académique : 2025-2026

Sommaire

Dédicaces	ii
Remerciements	iii
Résumé	iv
Abstract	v
Table des matières	vi
Table des figures	vii
Liste des tableaux	viii
Liste des sigles et acronymes	ix
Introduction Générale	1
1 Contexte et enjeux du projet	3
2 Concepts théoriques et modèles de demande spatiale	10
3 Architecture des données et couche analytique	23
4 Spécification du modèle structurel bayésien de la demande potentielle	36
5 Discussion et Analyse des Résultats	47
Conclusion Générale et Perspectives	59
Bibliographie	61
Annexe	63

Dédicaces

“

À ma mère.

À mon oncle.

À ma famille.

”

- ***Taha***

Remerciements

Je tiens tout d’abord à exprimer ma gratitude à mon professeur encadrant, dont les conseils ont été déterminants tant sur le plan de la modélisation et de l’analyse que sur celui de la structuration de ce rapport. Ses remarques précises et ses orientations m’ont permis d’adopter une approche rigoureuse, à l’articulation entre les enjeux académiques et les problématiques métier.

Mes remerciements s’adressent également à mon encadrant en entreprise, pour m’avoir offert l’opportunité de découvrir le domaine des données géospatiales appliquées au retail. Cette expérience a enrichi mes compétences en ingénierie des données tout en élargissant mon champ de vision vers des applications stratégiques.

Je souhaite aussi reconnaître la contribution inestimable de la communauté open source et des chercheurs qui mettent librement à disposition leurs travaux. Leur engagement à diffuser le savoir sans contrainte constitue un levier essentiel d’innovation et de progrès, dont ce projet est une illustration concrète.

Enfin, je remercie l’entreprise Label’Vie pour son accueil, la qualité de son environnement de travail ainsi que les moyens mis à disposition. Le soutien et les encouragements reçus, y compris financiers, témoignent d’une volonté d’investir dans les compétences et d’accompagner la montée en valeur des jeunes talents au Maroc.

Résumé

Ce projet de fin d'études propose un cadre bayésien structurel pour l'évaluation du potentiel commercial des nouvelles implantations en grande distribution alimentaire, appliqué à l'enseigne marocaine Label'Vie. Face aux limites des approches déterministes classiques, le modèle développé repose sur un cadre de choix discret articulant deux composantes distinctes : une composante d'attractivité, modélisant la préférence relative des consommateurs pour chaque point de vente accessible via une utilité déterministe V_{gs} , et une composante de marché, quantifiant la capacité de dépense alimentaire locale M_g à partir de données géospatiales, démographiques et socio-économiques. L'allocation probabiliste de la demande entre magasins est réalisée via un modèle logit multinomial avec option extérieure, étendu en logit niché par format commercial. L'inférence bayésienne permet de produire, pour chaque site candidat, une distribution a posteriori du chiffre d'affaires potentiel plutôt qu'une simple valeur ponctuelle, intégrant ainsi explicitement l'incertitude dans l'aide à la décision. Les données mobilisées combinent des sources internes à Label'Vie et des sources territoriales ouvertes : grilles de population GHS, points d'intérêt OpenStreetMap, données HCP et informations concurrentielles issues de scraping encadré. Les résultats montrent la faisabilité opérationnelle du cadre et ouvrent des perspectives pour un outil de simulation et de priorisation des sites d'expansion à l'échelle nationale.

Mots clés : modélisation bayésienne, choix discret, grande distribution, potentiel commercial, implantation, données géospatiales, logit niché, inférence probabiliste.

Abstract

This final year project presents a structural Bayesian framework for evaluating the commercial potential of new store locations in the food retail sector, applied to the Moroccan retail chain Label’Vie. In response to the limitations of classical deterministic approaches, the model is built around a discrete choice framework combining two distinct components: an attractiveness component, capturing consumers’ relative preferences for accessible stores through a deterministic utility function V_{gs} , and a market component, quantifying local food expenditure capacity M_g using geospatial, demographic, and socioeconomic data. Demand is allocated probabilistically across stores via a multinomial logit model with an outside option, extended to a nested logit structure by retail format. Bayesian inference yields, for each candidate site, a full posterior distribution of potential revenue rather than a single point estimate, explicitly embedding uncertainty into the decision-making process. The data sources combine internal Label’Vie records with open territorial data: GHS population grids, OpenStreetMap points of interest, HCP household expenditure statistics, and competitor information gathered through structured web scraping. Results demonstrate the operational feasibility of the framework and lay the groundwork for a simulation tool capable of ranking expansion sites at national scale.

Keywords : Bayesian modeling, discrete choice, food retail, commercial potential, store location, geospatial data, nested logit, probabilistic inference.

Table des matières

Dédicaces	ii
Remerciements	iii
Résumé	iv
Abstract	v
Table des matières	vi
Table des figures	vii
Liste des tableaux	viii
Liste des sigles et acronymes	ix
Introduction Générale	1
1 Contexte et enjeux du projet	3
Introduction	3
1.1 Présentation de l'organisme d'accueil	3
1.2 Contexte industriel et enjeux de l'expansion	5
1.3 Problématique et limites des pratiques actuelles	6
1.4 Cahier des charges fonctionnel et technique	7
1.5 État de l'art des approches de localisation et de géomarketing	7
1.6 Valeur ajoutée attendue pour l'organisation	8
Conclusion	8
2 Concepts théoriques et modèles de demande spatiale	10
Introduction	10
2.1 Modèles de choix discret	11
2.1.1 Utilité aléatoire et logit multinomial (MNL)	11
2.1.2 Le modèle logit niché (nested logit)	14
2.2 Modèles gravitaires et modèle de Huff	15
2.3 Inférence bayésienne	16
2.3.1 Théorème de Bayes et loi a posteriori	17
2.3.2 Optimisation et inférence variationnelle	18
2.4 Conclusion	21
3 Architecture des données et couche analytique	23

Introduction	23
3.1 Définition de la grille spatiale élémentaire	24
3.1.1 Choix de la maille spatiale	24
3.1.2 Critères de découpage et contraintes opérationnelles	25
3.1.3 Implications pour la modélisation et l'interprétation	25
3.2 Panorama des sources de données	26
3.2.1 Données internes de l'enseigne	26
3.2.2 Données de mobilité et de fréquentation	27
3.2.3 Données cartographiques et réseau	28
3.2.4 Données démographiques et socio-économiques	29
3.2.5 Données concurrentielles	29
3.3 Conception des flux de données ETL	30
3.3.1 Ingestion et standardisation des sources	30
3.3.2 Géocodage et enrichissement spatial	31
3.4 Construction des indicateurs géospatiaux	31
3.5 Conception et gouvernance de la couche analytique	33
3.5.1 Modèle de données analytique	33
3.5.2 Traçabilité, documentation et reproductibilité	34
4 Spécification du modèle structurel bayésien de la demande potentielle	36
Introduction	36
4.1 Architecture générale du modèle	36
4.2 Spécification de la composante d'utilité V_{gs}	38
4.3 Spécification de la composante de marché M_g	41
4.4 Couplage probabiliste entre offre et marché	43
Conclusion	46
5 Discussion et Analyse des Résultats	47
Introduction	47
5.1 Convergence de l'inférence variationnelle	48
5.2 Performance prédictive hors-échantillon	50
5.2.1 Métriques globales et erreurs par format	50
5.2.2 Intervalles prédictifs	51
5.2.3 Vérification de la cohérence ordinale par format	52
5.3 Diagnostics structurels du modèle	54
5.3.1 Décomposition du diagnostic DISCOUNTER	54
5.3.2 Diagnostic a priori–a posteriori des paramètres structurels	54
5.4 Interprétation opérationnelle	56
5.5 Limites du modèle	57
Conclusion	58
Conclusion Générale et Perspectives	59
Bibliographie	61
Annexe	63

Table des figures

1.1	Positionnement des formats selon la proximité et la capacité de service.	4
2.1	Comparaison des méthodes d'inférence : MAP, MCMC et ADVI.	18
3.1	Distribution de la population par cellule de grille GHS-POP (100 m). La médiane (23 habitants) est nettement inférieure à la moyenne (67,8), témoignant de la concentration urbaine.	24
3.2	Illustration de la grille GHS appliquée à Casablanca. À gauche, la décomposition large de la ville en cellules GHS. À droite, un zoom local montrant un quartier décomposé et le centroïde matérialisé par une étoile jaune.	25
3.3	Exemple de sortie du pipeline de segmentation SAM3. L'image de gauche montre l'imagerie satellitaire à haute résolution avant traitement. L'image de droite illustre les polygones de bâtiments segmentés automatiquement par le modèle SAM3 de Meta AI. .	26
3.4	Distribution de la surface de vente par format commercial. La médiane globale (255 m ²) reflète la prédominance des formats Discounter et Proxi.	27
3.5	Distribution des distances grille-magasin. L'écart moyenne-médiane témoigne de la présence de paires à longue distance (zones rurales).	28
3.6	Répartition des points d'intérêt par catégorie. Les POIs de transport (bus, taxi, tram) dominant, suivis des services (pharmacy, school, mosquée).	29
3.7	Schéma analytique en flocon de neige	34
4.1	Allocation de la demande depuis le centroïde de la grille (étoile jaune) vers les magasins environnants (triangles) en fonction des probabilités de choix estimées.	44
5.1	Convergence de l'ELBO pour les trois variantes de vraisemblance. La courbe brute est complétée par une moyenne mobile qui révèle la tendance globale de l'optimisation. . .	49
5.2	Couverture empirique des intervalles HDI à 94% sur l'ensemble test. La ligne pointillée représente la couverture nominale.	51
5.3	Biais relatif par format et par modèle. Les valeurs positives indiquent une surestimation, les valeurs négatives une sous-estimation.	52
5.4	Corrélation de rang de Spearman entre revenu prédit et revenu observé, par format commercial et globalement, pour les trois variantes de vraisemblance.	53
5.5	Distribution a priori et a posteriori du coefficient d'accessibilité piétonne b_{walk} , par format commercial.	55
5.6	Distribution a priori et a posteriori du coefficient d'accessibilité automobile b_{drive} , par format commercial.	55
5.7	Distribution a priori et a posteriori du panier moyen base_pm , par format commercial. .	55
5.8	Distribution a priori et a posteriori du degré de liberté ν de la vraisemblance Student-T. .	55

Liste des tableaux

1.1	Principaux repères du Groupe Label’Vie en 2025.	4
5.1	Valeurs finales de l’ELBO après 5 000 itérations ADVI.	49
5.2	Performance hors-échantillon par format : MAPE, biais relatif, couverture HDI à 94% et échelles résiduelles des variantes Student-T.	50
5.3	Corrélation de rang (Spearman) et corrélation de Pearson en échelle logarithmique, par format et globalement (ensemble test, $n = 16$).	53
5.4	Deux magasins test expliquent l’instabilité du format DISCOUNTER.	54
5.5	Effet estimé d’un doublement du temps d’accès (marche ou voiture) sur l’attractivité d’un magasin, par format, pour le modèle Student-T. La valeur est calculée comme $(\exp(-b \cdot \ln 2) - 1) \times 100$	56

Liste des sigles et acronymes

ADVI	Automatic Differentiation Variational Inference
API	Application Programming Interface
CRS	Coordinate Reference System (système de référence de coordonnées)
EBITDA	Earnings Before Interest, Taxes, Depreciation and Amortization
ELBO	Evidence Lower Bound
EPSG	European Petroleum Survey Group (codes de systèmes de coordonnées)
ESRI	Environmental Systems Research Institute
GEV	Generalized Extreme Value
GHS-POP	Global Human Settlement Population Grid
HCP	Haut-Commissariat au Plan
HDI	Highest Density Interval
HMC	Hamiltonian Monte Carlo
IIA	Independence of Irrelevant Alternatives
L-BFGS	Limited-memory Broyden–Fletcher–Goldfarb–Shanno
MAPE	Mean Absolute Percentage Error
MCMC	Markov Chain Monte Carlo
NUTS	No-U-Turn Sampler
OSM	OpenStreetMap
OSRM	Open Source Routing Machine
POI	Point of Interest
RMSE	Root Mean Squared Error
SAM	Segment Anything Model
WGS84	World Geodetic System 1984

Introduction Générale

Le choix d'un emplacement constitue l'une des décisions les plus coûteuses et les plus structurantes du marketing mix d'un distributeur. Contrairement à une décision de prix ou de promotion, dont les effets peuvent être ajustés à court terme, une mauvaise décision de localisation engage l'entreprise sur plusieurs années et conditionne durablement sa performance. La littérature en économie spatiale et en distribution montre ainsi que la performance d'un point de vente dépend fondamentalement de sa proximité aux consommateurs, mais également de la structure concurrentielle dans laquelle il s'insère.

Cette tension entre proximité et concurrence constitue le cœur des modèles de localisation commerciale. D'un côté, les enseignes cherchent à se rapprocher des zones de forte demande afin de réduire les coûts de déplacement des ménages et augmenter leur accessibilité. De l'autre, ce rapprochement entraîne mécaniquement une intensification de la concurrence, puisque les retailers tendent à se co-localiser dans les mêmes zones attractives. Ce phénomène, connu sous le nom d'*agglomération*, joue un rôle central dans la structuration des marchés de détail.

L'agglomération peut prendre plusieurs formes. Elle est dite inter-type lorsqu'elle regroupe des formats différents (supermarchés, hypermarchés, commerces spécialisés) au sein d'un même pôle commercial, et intra-type lorsqu'elle concerne des enseignes similaires (par exemple plusieurs restaurants, banques ou magasins de bricolage dans une même zone). Cette co-localisation génère deux effets opposés. Elle peut d'une part accroître l'attractivité globale d'une zone en réduisant les coûts de recherche et en favorisant le multi-shopping, transformant ainsi un ensemble de magasins en une véritable destination commerciale. D'autre part, elle intensifie la concurrence directe pour le revenu disponible des consommateurs. Le résultat net de ces forces opposées dépend de leur équilibre et peut varier selon les formats et les contextes urbains.

Dans ce cadre, la littérature récente en retail location et en économétrie des choix discrets a montré l'importance de modéliser explicitement les décisions de fréquentation à travers des modèles structurels de choix spatial. Ces approches permettent de relier l'utilité d'un consommateur à un point de vente à des variables fondamentales telles que le temps de trajet, la distance, le format du magasin ou encore son environnement concurrentiel, tout en intégrant des interactions entre enseignes [1].

Au Maroc, ces enjeux prennent une dimension particulière. Les dynamiques urbaines récentes, caractérisées par l'étalement des périphéries, la densification de certaines centralités et l'émergence de nouveaux corridors commerciaux, redessinent en profondeur les structures de chalandise. Dans ce contexte, un acteur majeur de la grande distribution tel que **Label'Vie**, engagé dans une stratégie multi-format (hypermarchés, supermarchés et proximité), doit dépasser les approches purement empiriques pour s'appuyer sur des modèles quantitatifs capables de représenter ces mécanismes de localisation et de concurrence.

L'objectif de ce travail est de construire un modèle spatial de dépenses des consommateurs intégrant explicitement les dimensions de distance, de format et d'environnement concurrentiel. Le point de départ est la modélisation de l'utilité d'un couple consommateur-magasin, traduite en probabilités de choix permettant d'expliquer et de prédire la répartition du chiffre d'affaires entre enseignes.

Pour alimenter ce modèle, un pipeline de données multi-sources est mis en place, combinant données géographiques et socio-démographiques, informations internes sur les magasins, réseaux routiers et images satellites exploitées pour la construction de variables décrivant l'environnement spatial des points de vente. Le modèle est ensuite estimé dans un cadre bayésien, permettant d'intégrer l'incertitude paramétrique et de capturer les hétérogénéités de comportement entre zones et formats. Ce travail poursuit quatre objectifs principaux :

- Collecter, intégrer et structurer un ensemble multi-sources de données géolocalisées sur les principales agglomérations marocaines, selon les principes des schémas relationnels géospatiaux.
- Spécifier et estimer un modèle de choix discret reliant l'utilité consommateur-magasin à la distance, au format, à la surface et aux effets de concurrence locale.
- Calibrer le modèle afin d'obtenir des distributions a posteriori des paramètres et d'analyser les élasticités spatiales.
- Confronter les prédictions aux performances observées et produire un outil de simulation évaluant l'impact potentiel de nouvelles implantations.

Ce rapport est structuré en cinq chapitres. Le premier présente l'organisme d'accueil et les enjeux stratégiques liés à la localisation. Le deuxième synthétise les fondements théoriques des modèles de choix spatial. Le troisième détaille la construction du pipeline de données. Le quatrième est consacré à la spécification et à l'estimation du modèle bayésien. Le cinquième présente les résultats empiriques et leurs implications managériales.

Contexte et enjeux du projet

Introduction

Ce chapitre regroupe la présentation de l'organisme d'accueil, le contexte industriel du projet et la formalisation du besoin métier. L'objectif est de relier directement le cadre institutionnel de Label'Vie à la problématique traitée dans ce mémoire : l'évaluation du potentiel d'implantation des magasins à partir de données géospatiales, commerciales et socio-économiques.

La présentation de l'entreprise n'est donc pas abordée comme un élément séparé du projet. Elle permet de comprendre pourquoi la localisation commerciale constitue un enjeu stratégique pour le Groupe : croissance rapide du réseau, diversité des formats, concurrence territoriale, investissement élevé associé à chaque ouverture et besoin croissant d'outils analytiques reproductibles. Le chapitre présente d'abord Label'Vie et son modèle multiformat, puis précise les enjeux de l'expansion retail au Maroc, les limites des pratiques actuelles, le cahier des charges de la solution attendue et le positionnement de l'approche proposée par rapport aux méthodes classiques de géomarketing.

1.1 Présentation de l'organisme d'accueil

Groupe Label'Vie et positionnement dans la distribution moderne

Fondé en 1986, le Groupe **Label'Vie** est aujourd'hui l'un des principaux acteurs de la grande distribution alimentaire au Maroc. Son développement s'est accéléré après son introduction à la Bourse de Casablanca en 2008 et la conclusion du partenariat de franchise avec **Carrefour** en 2009. Le Groupe opère un modèle de distribution multiformat lui permettant d'adresser plusieurs usages de consommation : achats complets en hypermarché, courses de supermarché, proximité urbaine, discount et cash-and-carry.

À fin 2025, le réseau compte **411 magasins** pour une surface globale de **362 909 m²**. Le chiffre d'affaires consolidé atteint **18 534 MDH**, l'EBITDA **1 557 MDH** et le résultat net **594 MDH**. Ces indicateurs traduisent une croissance portée à la fois par l'amélioration du réseau existant et par l'accélération des ouvertures, avec **141 nouveaux magasins en 2025**. Ces ordres de grandeur montrent que la question de l'expansion n'est pas marginale : elle se situe au cœur du modèle de développement de l'entreprise.

Indicateur	Situation 2025
Activité principale	Grande distribution alimentaire
Statut boursier	Cotée à la Bourse de Casablanca depuis 2008
Partenaire enseigne	Carrefour, depuis 2009
Réseau	411 magasins
Surface globale	362 909 m ²
Chiffre d'affaires	18 534 MDH
EBITDA	1 557 MDH
Résultat net	594 MDH
Clients servis	93 millions

Table 1.1 : Principaux repères du Groupe Label'Ve en 2025.

Le portefeuille commercial est composé de formats complémentaires : **Carrefour Hyper**, **Carrefour Market**, **Carrefour Express**, **Atacadão** et **Supeco**. Cette diversité n'est pas seulement une segmentation marketing, elle détermine la manière dont chaque magasin interagit avec son territoire. Un hypermarché dépend d'un bassin de chalandise large et d'une accessibilité automobile forte, tandis qu'un format de proximité dépend davantage de la densité résidentielle, du passage et des achats fréquents. Un modèle d'implantation doit donc être capable de différencier ces logiques au lieu de traiter tous les magasins comme des points équivalents sur une carte.




Figure 1.1 : Positionnement des formats selon la proximité et la capacité de service.

Fonctions mobilisées autour du projet

Le projet s'inscrit dans les activités liées à la **Market Intelligence**, au géomarketing et à l'expansion du réseau. Ces fonctions exploitent des données internes, telles que les ventes, les caractéristiques magasins et les performances commerciales, ainsi que des données externes décrivant la population, les points d'intérêt, la concurrence, les réseaux routiers et l'environnement urbain. Leur rôle est d'éclairer les décisions de développement : qualification des zones, comparaison de sites candidats, suivi de la

concurrence et analyse du potentiel commercial.

Cette organisation explique le besoin d'une méthode plus structurée. Lorsque le réseau s'étend rapidement et que les ouvertures couvrent des territoires de plus en plus hétérogènes, l'expertise terrain reste indispensable, mais elle doit être complétée par une couche analytique homogène. Le projet répond précisément à cette articulation entre connaissance métier et modélisation quantitative.

1.2 Contexte industriel et enjeux de l'expansion

Grande distribution alimentaire au Maroc

Le secteur marocain de la distribution alimentaire reste caractérisé par la coexistence de deux logiques. D'un côté, les enseignes modernes poursuivent leur extension territoriale et diversifient leurs formats pour répondre à des marchés urbains, périurbains et émergents. De l'autre, le commerce traditionnel conserve une place importante dans les habitudes d'achat, en particulier pour les courses de proximité et les achats fréquents. Cette dualité impose aux distributeurs modernes de ne pas raisonner uniquement en nombre d'ouvertures, mais en adéquation fine entre un format commercial, une zone de chalandise et un comportement de consommation local.

Dans ce contexte, la localisation devient un déterminant majeur de la performance. Elle conditionne la taille du bassin adressable, le niveau de concurrence, la visibilité du magasin, les temps d'accès et la capacité à capter des flux réguliers. Les mutations démographiques renforcent cette exigence : croissance du nombre de ménages, urbanisation, transformation de l'habitat et amélioration progressive des infrastructures créent de nouveaux bassins de consommation, mais aussi une concurrence plus forte sur les meilleurs emplacements.

Implantation commerciale : une décision coûteuse et peu réversible

L'ouverture d'un magasin engage des dépenses immobilières, logistiques, humaines et opérationnelles importantes. Contrairement à une campagne commerciale ou à un ajustement d'assortiment, une implantation est difficilement réversible. Une erreur de localisation peut produire une sous-performance durable, à l'inverse, un site bien choisi peut sécuriser un avantage concurrentiel de long terme.

Le problème opérationnel consiste donc à déterminer dans quelles conditions une localisation peut soutenir durablement la performance d'un point de vente. Cette question ne peut pas être résolue par un seul indicateur. Elle nécessite de croiser la population desservie, le pouvoir d'achat, l'accessibilité, le format envisagé, la concurrence, la cannibalisation potentielle avec le réseau existant et les caractéristiques locales du territoire.

Positionnement du projet dans la stratégie de croissance

La stratégie de croissance du Groupe donne une place centrale à l'expansion du réseau. La présentation aux analystes FY 2025 met en évidence une accélération des ouvertures, avec **141 nouveaux magasins en 2025**, et une couverture de **37 villes**, dont **4 nouvelles villes**. À l'horizon 2028, l'ambition annoncée repose sur un chiffre d'affaires cible de **27,9 Md MAD**, une marge d'EBITDA cible de **9,3%**, **5,3 Md MAD** d'investissements prévus et un développement réseau de **774 nouveaux sites**.

Ces objectifs renforcent la nécessité d'un cadre d'évaluation robuste. Plus le nombre de sites à étudier augmente, plus il devient difficile de s'appuyer uniquement sur des analyses ponctuelles. L'enjeu n'est pas de remplacer l'expertise expansion, mais de lui fournir une base de comparaison systématique, capable de hiérarchiser les opportunités et de signaler les risques invisibles dans une lecture descriptive.

1.3 Problématique et limites des pratiques actuelles

Décisions d'implantation fondées sur des heuristiques territoriales

Les décisions d'ouverture reposent traditionnellement sur l'expérience des équipes, les visites terrain, la lecture cartographique et quelques indicateurs descriptifs tels que la population, la surface disponible ou la présence de concurrents. Ces pratiques restent indispensables, car elles intègrent une connaissance fine du terrain que les données ne capturent pas toujours. Leur limite apparaît lorsque le rythme d'expansion augmente et que les sites à comparer deviennent nombreux, hétérogènes et éloignés des marchés déjà connus.

Une analyse fondée principalement sur des heuristiques rend difficile la comparaison objective de deux sites. Les hypothèses sont parfois implicites, les indicateurs ne sont pas toujours calculés de manière reproductible et l'incertitude associée à la prévision n'est pas formalisée. Or le projet ne cherche pas seulement à classer des emplacements, il doit aider à comprendre pourquoi un site est risqué, quel facteur explique son potentiel et dans quelle mesure le résultat attendu reste fiable.

Besoin d'un cadre analytique probabiliste

La disponibilité de données commerciales, géospatiales et concurrentielles permet de dépasser une lecture purement descriptive. Le besoin n'est pas de produire une prédiction exacte du revenu futur d'un magasin, ce qui serait une promesse irréaliste. Il s'agit plutôt d'estimer un intervalle de résultats plausibles et d'identifier les variables qui déplacent cet intervalle : distance aux clients, accessibilité, densité résidentielle, typologie d'habitat, présence de points d'intérêt, pression concurrentielle et proximité d'autres magasins du réseau.

Cette approche probabiliste permet de traiter explicitement l'incertitude. Elle est particulièrement importante dans un contexte où les données sont hétérogènes, où les magasins existants n'ont pas été implantés aléatoirement et où certains territoires disposent de peu d'observations comparables. Le modèle attendu doit donc aider à raisonner en potentiel et en risque, plutôt qu'en valeur unique présentée comme certaine.

Question centrale du projet

La problématique peut être formulée ainsi : **comment construire un modèle géospatial et probabiliste capable d'estimer le potentiel commercial d'un magasin candidat, tout en tenant compte du format, de l'accessibilité, de la concurrence, de la demande locale et de l'incertitude associée à la prédiction ?**

Cette question se décline en quatre sous-objectifs : construire une couche de données territoriales fiable, formaliser les mécanismes de choix spatial entre magasins, estimer le revenu potentiel à partir des caractéristiques locales, restituer les résultats sous une forme interprétable pour les équipes métier.

1.4 Cahier des charges fonctionnel et technique

Données et couche analytique

La solution doit intégrer des données multi-sources couvrant l'ensemble du territoire étudié. Les données internes décrivent les magasins, les formats, les surfaces, les ventes observées et certains attributs commerciaux. Les données externes enrichissent cette vision par des informations démographiques, socio-économiques, géographiques et concurrentielles : population, ménages, points d'intérêt, réseau routier, équipements urbains, localisation des concurrents et données issues de l'observation spatiale.

Ces sources doivent être consolidées dans une couche analytique unifiée. Le rôle de cette couche n'est pas seulement de stocker des données, mais de produire des indicateurs comparables entre sites : accessibilité, densité de population, intensité concurrentielle, proximité des magasins existants, attractivité de l'environnement urbain et potentiel de dépense locale. Cette étape conditionne la qualité du modèle, car une modélisation bayésienne sophistiquée ne peut pas compenser des indicateurs mal construits ou incohérents entre territoires.

Fonctionnalités attendues

La solution attendue doit permettre l'évaluation du potentiel associé à une localisation candidate, la quantification de l'effet de la distance et de l'accessibilité, l'analyse de la pression concurrentielle, la mesure des phénomènes de cannibalisation et la simulation de scénarios d'implantation. Elle doit également restituer les résultats de manière lisible : prédiction centrale, intervalle d'incertitude, facteurs explicatifs et comparaison avec des magasins existants comparables.

L'objectif n'est pas de produire un score opaque, mais un outil d'aide à la décision. Les équipes doivent pouvoir comprendre pourquoi un site obtient un potentiel élevé ou faible, et distinguer un site réellement prometteur d'un site dont la prédiction est trop incertaine pour justifier une décision rapide.

Contraintes opérationnelles et gouvernance

La méthode doit être reproductible, documentée et compatible avec un usage régulier. Les traitements doivent pouvoir être relancés sur de nouveaux sites sans reconstruire toute la chaîne analytique. Les temps de calcul doivent rester compatibles avec une phase d'étude métier, même si certaines étapes de modélisation lourde peuvent être exécutées hors interaction directe.

La confidentialité des données commerciales impose une séparation claire entre les données brutes, les indicateurs calculés et les livrables de restitution. Les accès, les hypothèses de modélisation et les versions des jeux de données doivent être traçables afin de permettre l'audit des résultats.

1.5 État de l'art des approches de localisation et de géomarketing

Zones de chalandise et modèles gravitaires

Dans les pratiques courantes du retail, l'étude d'un emplacement commence souvent par la délimitation d'une zone de chalandise. Les équipes utilisent des isochrones, par exemple des zones accessibles en

cinq, dix ou quinze minutes, afin d'estimer le bassin de population réellement atteignable autour d'un site. Cette première lecture est utile, car elle traduit une contrainte opérationnelle simple : un magasin ne s'adresse pas à toute une ville, mais à une population qui peut l'atteindre avec un coût de déplacement acceptable.

Les modèles gravitaires formalisent cette intuition en reliant l'attractivité d'un magasin à sa taille et à son éloignement. Ils permettent de construire des zones de chalandise théoriques et d'estimer des flux potentiels entre zones résidentielles et points de vente. Leur intérêt est leur simplicité et leur lisibilité métier, leur limite est qu'ils reposent souvent sur des paramètres fixes et sur une représentation partielle de la concurrence.

Limites des approches classiques au regard du projet

Les méthodes classiques restent limitées pour le besoin traité. Les isochrones donnent une lecture claire de l'accessibilité, mais ils ne disent pas à eux seuls quelle part de la population choisira effectivement le magasin. Les indicateurs agrégés à la commune ou au quartier sont faciles à exploiter, mais ils masquent des différences fines entre zones proches : densité résidentielle, rupture urbaine, axes routiers, présence d'équipements, concurrence immédiate ou typologie de l'habitat.

La contribution attendue consiste à enrichir l'expertise retail existante par une modélisation plus fine, capable de travailler à une maille géographique plus granulaire, de comparer les sites de manière homogène et d'exprimer l'incertitude associée aux résultats. Cette transition justifie la construction d'une couche de données plus fine et d'un modèle de demande potentielle adapté à l'hétérogénéité spatiale.

1.6 Valeur ajoutée attendue pour l'organisation

La valeur ajoutée du projet tient à la transformation d'un raisonnement souvent qualitatif en un processus analytique documenté. Pour la fonction expansion, la solution doit fournir une comparaison plus robuste des sites candidats et mettre en évidence les risques invisibles dans une analyse descriptive, notamment la cannibalisation, la faiblesse du bassin adressable ou la dépendance excessive à une hypothèse de trafic.

Pour la fonction marketing, les résultats permettent de mieux comprendre la relation entre format, distance et profil de clientèle. Ils peuvent alimenter le ciblage local, l'analyse des zones de chalandise et l'adaptation des actions commerciales autour d'un magasin existant ou futur.

Pour l'organisation, la couche de données géospatiales et les modèles associés constituent un actif réutilisable. Ils peuvent servir à l'expansion, mais aussi à l'optimisation du réseau existant, à l'analyse concurrentielle et à la priorisation des investissements. La valeur du projet réside donc autant dans le modèle que dans la méthode reproductible qu'il installe.

Conclusion

Ce chapitre a posé le cadre général du projet. Label'Vie se distingue par un modèle multiformat, une stratégie d'expansion soutenue et une maturité data en cours de structuration. Ces éléments rendent nécessaire une approche plus systématique de l'évaluation des implantations. Les pratiques fondées

sur les isochrones, les indicateurs agrégés et les modèles de choix spatial fournissent un socle utile, mais leurs limites motivent la construction d'une couche de données géospatiales plus fine et d'un modèle probabiliste de demande potentielle. Le chapitre suivant présente la mise en place de cette infrastructure de données et les traitements nécessaires à la modélisation.

Concepts théoriques et modèles de demande spatiale

Introduction

Ce chapitre a pour objectif de présenter les bases conceptuelles, méthodologiques et mathématiques sur lesquelles repose notre travail. L'enjeu n'est pas de décrire la mise en œuvre pratique, mais de fournir un cadre théorique solide permettant de comprendre les choix techniques adoptés par la suite. Nous nous inscrivons ainsi dans une double logique : d'une part, situer notre projet par rapport aux approches existantes dans la littérature scientifique et, d'autre part, expliciter les modèles et outils qui constituent les fondements de notre solution.

La modélisation du choix spatial de magasin mobilise un corpus théorique interdisciplinaire, à la croisée de l'économétrie comportementale, de l'économie géographique et de la statistique bayésienne. Ces trois disciplines ne constituent pas des couches indépendantes empilées les unes sur les autres, mais des niveaux d'analyse complémentaires répondant chacun à une question distincte : pourquoi un consommateur choisit-il un point de vente plutôt qu'un autre, dans quel environnement spatial ce choix s'effectue-t-il, et comment estimer les paramètres correspondants de manière robuste en présence d'hétérogénéité territoriale et d'incertitude.

Nous débutons par la théorie de l'utilité aléatoire, fondement microéconomique des modèles de choix discrets, dont nous rappelons les axiomes, les propriétés structurelles et les implications en termes de substitution entre alternatives concurrentes. Nous poursuivons par une discussion des modèles gravitaires et du modèle de Huff, qui structurent la demande spatiale. Nous regroupons enfin les modèles hiérarchiques et l'inférence bayésienne, cadre dans lequel le modèle est estimé et qui permet de restituer les prédictions sous forme de distributions exploitables pour la décision d'implantation.

Ce chapitre pose les fondements théoriques du modèle de choix spatial de magasin que nous employons. Trois piliers structurent notre cadre : la théorie de l'utilité aléatoire et les modèles de choix discrets, les modèles gravitaires et hiérarchiques qui structurent l'ancrage spatial, puis l'inférence bayésienne qui permet l'estimation robuste et la quantification de l'incertitude. Ces trois axes ne sont pas indépendants, ils forment un pipeline cohérent qui va du comportement individuel à son ancrage spatial, puis à son estimation.

La question que nous nous posons est la suivante : comment estimer la distribution du chiffre d'affaires d'un point de vente candidat, dans une zone géographique non ou peu observée dans les données

historiques ? Les approches gravitaires classiques, initiées par Reilly[2] et formalisées probabilistiquement par Huff[3], reposent sur une intuition économique correcte, l’attraction d’un magasin croît avec sa taille et décroît avec la distance, mais souffrent de limitations théoriques fondamentales : absence de cadre d’identification, paramètres globaux incapables de capturer l’hétérogénéité des préférences, et impossibilité de quantifier l’incertitude prédictive. Le cadre de l’utilité aléatoire, tel que développé par McFadden[4, 5], généralise ces modèles en les fondant sur un axiome comportemental, la maximisation de l’utilité, tout en offrant une structure probabiliste complète.

Nous exposons dans la première section la théorie de l’utilité aléatoire, du modèle logit multinomial à son extension imbriquée, qui relâche progressivement la propriété d’indépendance des alternatives irrélevantes. La deuxième section présente les modèles gravitaires et le modèle de Huff, qui traduisent ces principes en un cadre spatial explicite. La troisième section regroupe le cadre bayésien : modèles hiérarchiques, théorème de Bayes, optimisation MAP comme diagnostic rapide, autodifférentiation et ADVI comme méthode principale d’inférence. La dernière section présente l’écosystème logiciel mobilisé.

2.1 Modèles de choix discret

Les modèles de choix discret constituent le langage formel dans lequel s’exprime la théorie économique du comportement de décision face à un ensemble fini d’alternatives mutuellement exclusives. Ils offrent un cadre unifié reliant les préférences individuelles, mesurées par une fonction d’utilité, aux parts de marché observables, via une structure probabiliste rigoureuse. Cette section expose les fondements de la théorie de l’utilité aléatoire, aboutit à la formulation du modèle logit multinomial, puis discute ses limites et les extensions principales.

2.1.1 Utilité aléatoire et logit multinomial (MNL)

2.1.1.1 Fondements de la théorie de l’utilité aléatoire

Le cadre de l’utilité aléatoire, initié par Thurstone¹ et formalisé par Marschak[6], postule que tout décideur choisit l’alternative qui maximise son utilité. Soit un décideur n confronté à un ensemble de choix $\mathcal{J} = \{1, \dots, J\}$ fini, exhaustif et mutuellement exclusif. L’utilité que le décideur retire de l’alternative j s’écrit :

$$U_{nj} = V_{nj} + \varepsilon_{nj}, \quad \forall j \in \mathcal{J}, \quad (2.1)$$

où V_{nj} désigne la composante observable de l’utilité, fonction des caractéristiques de l’alternative x_{nj} et du décideur s_n , tandis que ε_{nj} capture tout ce qui échappe à l’observateur : goûts non mesurés, contexte situationnel, ou simplement la limite de la spécification du chercheur. Le décideur choisit l’alternative i si et seulement si $U_{ni} > U_{nj}$ pour tout $j \neq i$.

Le chercheur, privé d’un accès direct à U_{nj} , ne peut formuler que des affirmations probabilistes sur le choix. La probabilité que le décideur n sélectionne l’alternative i s’exprime comme une intégrale multidimensionnelle sur la densité conjointe $f(\varepsilon_n)$ des termes non observés :

$$P_{ni} = \int_{\mathcal{D}} \mathbb{I}(\varepsilon_{nj} - \varepsilon_{ni} < V_{ni} - V_{nj}, \forall j \neq i) f(\varepsilon_n) d\varepsilon_n, \quad (2.2)$$

¹Thurstone (1927), *Law of Comparative Judgment*.

où $\mathcal{D}$ est le domaine de définition de $\varepsilon_n = (\varepsilon_{n1}, \dots, \varepsilon_{nJ})$ et $\mathbb{I}(\cdot)$ la fonction indicatrice. Chaque modèle de choix discret émerge d'une spécification particulière de cette densité[7].

2.1.1.2 Dérivation du modèle logit

Le modèle logit multinomial (MNL) résulte de l'hypothèse que les termes ε_{nj} sont indépendants et identiquement distribués selon une loi de valeurs extrêmes de type I (dite aussi distribution de Gumbel), de densité :

$$f(\varepsilon_{nj}) = \exp(-\varepsilon_{nj} - e^{-\varepsilon_{nj}}), \quad (2.3)$$

et de fonction de répartition $F(\varepsilon_{nj}) = \exp(-e^{-\varepsilon_{nj}})$. Cette distribution présente une variance égale à $\pi^2/6$, ce qui fixe implicitement l'échelle de l'utilité. La moyenne de la distribution de valeurs extrêmes n'est pas nulle, mais elle est sans incidence car seules les différences d'utilité importent pour le choix, et la différence de deux variables de même moyenne a elle-même une moyenne nulle. La différence de deux variables de valeurs extrêmes indépendantes suit une distribution logistique :

$$F(\varepsilon_{nj} - \varepsilon_{ni}) = \frac{e^{\varepsilon_{nj} - \varepsilon_{ni}}}{1 + e^{\varepsilon_{nj} - \varepsilon_{ni}}}, \quad (2.4)$$

forme exploitée directement dans le cas binaire. L'hypothèse cruciale n'est pas tant la forme de la distribution que l'indépendance des erreurs entre alternatives : l'inobservable affectant l'utilité d'une alternative n'apporte aucune information sur l'inobservable affectant une autre. Cette hypothèse, bien que restrictive, peut s'interpréter comme l'aboutissement d'une spécification soigneuse de V_{nj} : si le chercheur parvient à capturer toutes les sources de corrélation systématique dans la partie observable, le résidu est effectivement du bruit blanc.

McFadden[4] a établi l'équivalence entre trois caractérisations du modèle logit : (i) les erreurs sont iid valeurs extrêmes, (ii) les probabilités de choix prennent la forme logit, et (iii) les probabilités satisfont la propriété d'indépendance face aux alternatives irrélevantes (IIA).

En intégrant l'expression (2.3) sur la densité de ε_{ni} , on obtient la formule fermée emblématique :

$$P_{ni} = \frac{\exp(V_{ni})}{\sum_{j \in \mathcal{J}} \exp(V_{nj})}. \quad (2.5)$$

Cette expression possède plusieurs propriétés souhaitables. D'abord, P_{ni} appartient nécessairement à l'intervalle $]0, 1[$ et les probabilités somment à un. Ensuite, la relation entre la probabilité et l'utilité représentative est sigmoïde, en forme de S : lorsque V_{ni} est très inférieure à celle des autres alternatives, un accroissement de V_{ni} a peu d'effet sur P_{ni} car les autres alternatives demeurent nettement préférables, à l'inverse, lorsque V_{ni} est très supérieure, la probabilité est déjà proche de un et un accroissement supplémentaire a peu d'effet. L'impact marginal est maximal lorsque la probabilité est voisine de 0.5, c'est-à-dire lorsque le décideur est indécis.

2.1.1.3 Spécification linéaire et identification

L'utilité représentative se spécifie habituellement comme linéaire en paramètres :

$$V_{nj} = \beta' x_{nj}, \quad (2.6)$$

où x_{nj} est un vecteur de variables observables relatives à l'alternative j et β un vecteur de paramètres inconnus. Sous cette spécification, les probabilités logit s'écrivent :

$$P_{ni} = \frac{\exp(\beta' x_{ni})}{\sum_{j \in \mathcal{J}} \exp(\beta' x_{nj})}. \quad (2.7)$$

McFadden[4] a démontré que la fonction log-vraisemblance associée est globalement convexe en β , ce qui garantit l'unicité du maximum et facilite considérablement les procédures d'optimisation numérique.

L'identification du modèle repose sur deux contraintes structurelles. Premièrement, seuls les *différences* d'utilité importent : l'ajout d'une constante à l'utilité de toutes les alternatives ne modifie pas le choix. Cette propriété implique qu'au plus $J - 1$ constantes alternatives-spécifiques peuvent entrer dans le modèle, la J -ième étant normalisée à zéro. Deuxièmement, l'*échelle* de l'utilité est arbitraire : multiplier chaque utilité par une constante strictement positive ne change pas l'alternative qui la maximise. La normalisation conventionnelle fixe la variance des erreurs à $\pi^2/6$, ce qui revient à normaliser l'échelle. Les coefficients estimés β sont en réalité des rapports β^*/σ , où β^* sont les coefficients "vrais" et σ le paramètre d'échelle lié à la variance des facteurs non observés. Un σ plus élevé, reflétant une plus grande hétérogénéité non mesurée, produit des coefficients plus faibles même si l'impact des variables observées sur l'utilité reste identique. En revanche, les *rapports* de coefficients sont invariants à l'échelle, car σ s'annule dans le quotient.

2.1.1.4 Estimation par maximum de vraisemblance

Soit un échantillon de N décideurs, avec $y_{ni} = 1$ si le décideur n a choisi l'alternative i et zéro sinon. La fonction de vraisemblance est le produit des probabilités des alternatives choisies :

$$L(\beta) = \prod_{n=1}^N \prod_{i \in \mathcal{J}} (P_{ni})^{y_{ni}}, \quad (2.8)$$

et la log-vraisemblance s'écrit :

$$\ell(\beta) = \sum_{n=1}^N \sum_{i \in \mathcal{J}} y_{ni} \ln(P_{ni}). \quad (2.9)$$

L'estimateur $\hat{\beta}$ est la valeur qui maximise cette fonction. Au maximum, les conditions du premier ordre s'écrivent :

$$\sum_{n=1}^N \sum_{i \in \mathcal{J}} (y_{ni} - P_{ni}) x_{ni} = 0. \quad (2.10)$$

Cette équation caractérise l'estimateur de manière intuitive : les estimates de maximum de vraisemblance sont les valeurs de β qui égalisent, pour chaque variable explicative, la moyenne observée sur les alternatives choisies à la moyenne prédite par le modèle sur l'ensemble des alternatives. Le résidu $y_{ni} - P_{ni}$, différence entre le choix effectif et sa probabilité prédite, est non corrélé avec les variables explicatives, à l'image des conditions d'orthogonalité des moindres carrés ordinaires dans le modèle de régression linéaire.

2.1.2 Le modèle logit niché (nested logit)

Pour toute paire d'alternatives i et k , le rapport des probabilités logit ne dépend que de ces deux alternatives :

$$\frac{P_{ni}}{P_{nk}} = \frac{\exp(V_{ni}) / \sum_j \exp(V_{nj})}{\exp(V_{nk}) / \sum_j \exp(V_{nj})} = \exp(V_{ni} - V_{nk}). \quad (2.11)$$

Le dénominateur commun s'annule : le rapport de probabilités entre i et k est indépendant de la présence ou des caractéristiques de toute autre alternative $j \neq i, k$. C'est la propriété d'*indépendance face aux alternatives irrélevantes* (IIA pour *Independence From Irrelevant Alternatives*), initialement axiomatisée par Luce[8].

L'IIA se manifeste également par le biais des élasticités croisées. La dérivée de la probabilité de l'alternative i par rapport à une variable z entrant dans l'utilité de l'alternative j ($j \neq i$) est :

$$\frac{\partial P_{ni}}{\partial z_{nj}} = -\beta_z z_{nj} P_{nj} P_{ni}. \quad (2.12)$$

L'élasticité croisée $E_{i,z_{nj}} = -\beta_z z_{nj} P_{nj}$ est identique pour toutes les alternatives $i \neq j$: une amélioration de l'alternative j réduit les probabilités de toutes les autres alternatives dans la même proportion. Si la probabilité de l'une d'elles diminue de dix pour cent, celle de toutes les autres diminue également de dix pour cent. Ce schéma de *substitution proportionnelle* est réaliste lorsque les alternatives sont véritablement hétérogènes, mais inadapté lorsque certaines alternatives sont plus proches les unes des autres qu'elles ne le sont des autres.

Pour contourner la rigidité de l'IIA tout en conservant l'avantage computationnel d'une forme fermée, le modèle logit niché organise les alternatives en *groupes* (ou *nests*) au sein desquels les erreurs sont corrélées, tandis qu'elles demeurent indépendantes entre groupes. McFadden[9] a montré que ce modèle appartient à la famille des valeurs extrêmes généralisées (GEV de Gumbel et Solomon, 1960) et admet une expression fermée des probabilités de choix.

Soit G l'ensemble des groupes et $R_g \subset \mathcal{J}$ l'ensemble des alternatives appartenant au groupe g . La probabilité de choisir l'alternative i dans le groupe $R_{g(i)}$ s'écrit en deux étapes :

$$P_{ni} = \underbrace{\frac{\exp(V_{ni}/\lambda_{g(i)})}{\sum_{j \in R_{g(i)}} \exp(V_{nj}/\lambda_g)}}_{\text{choix de } i \text{ dans le groupe } g(i)} \times \underbrace{\frac{\left[\sum_{j \in R_g} \exp(V_{nj}/\lambda_g) \right]^{\lambda_g}}{\sum_{g' \in G} \left[\sum_{k \in R_{g'}} \exp(V_{nk}/\lambda_{g'}) \right]^{\lambda_{g'}}}}_{\text{choix du groupe } g(i)}, \quad (2.13)$$

où $\lambda_g \in (0, 1]$ est le paramètre de corrélation du groupe g . Lorsque $\lambda_g = 1$, les erreurs sont indépendantes au sein du groupe et le modèle logit niché se réduit au MNL. Lorsque λ_g approche zéro, la corrélation au sein du groupe tend vers un, et le choix au sein du groupe devient purement aléatoire. La condition d'identification exige $\lambda_g \leq 1$, des valeurs supérieures à un violeraient l'axiome de rationalité[7].

Le paramètre λ_g contrôle directement le degré de corrélation entre les erreurs de deux alternatives i et j du même groupe : $\text{Corr}(\varepsilon_{ni}, \varepsilon_{nj}) = (\lambda_g^2 - 1)/2$. Plus λ_g est faible, plus les alternatives du groupe sont perçues comme similaires, et plus le modèle permet à une alternative voisine de capter des parts préférentiellement à ses voisines plutôt qu'aux alternatives des autres groupes. Dans notre contexte, on pourrait par exemple regrouper les magasins par format (supermarché, hypermarché, marché de

proximité) ou par enseigne, selon la structure de concurrence que l'on souhaite capturer.

2.2 Modèles gravitaires et modèle de Huff

Les modèles de choix discret abstraits présentés dans la section précédente trouvent dans les modèles gravitaires et le modèle de Huff leur première application à grande échelle au problème de la demande spatiale. Ces modèles traduisent l'intuition selon laquelle l'attraction exercée par une destination croît avec sa "taille" et décroît avec l'effort pour l'atteindre, en un formalisme probabiliste exploitable pour la prévision commerciale.

Formulation du modèle de Huff

L'analogie entre les flux spatiaux et la loi de la gravitation universelle de Newton a été mobilisée dès les années 1930 en géographie économique. Reilly[2] a formulé le *principe du point médian* : deux villes attractives partagent leur zone d'influence selon un point de rupture situé sur l'axe les reliant, tel que le rapport des distances au point de rupture soit inversement proportionnel au rapport des racines carrées de leurs populations. Plus formellement, si deux centres A et B de populations P_A et P_B sont séparés par une distance D_{AB} , le point de rupture se trouve à une distance de A égale à :

$$D_{AR} = \frac{D_{AB}}{1 + \sqrt{P_B/P_A}}. \quad (2.14)$$

Ce modèle, élégant dans sa simplicité, est déterministe et binaire : chaque origine est attribuée au centre le plus proche du point de vue de l'équilibre gravitaire. Il ne produit ni probabilités ni parts de marché, et ne s'étend pas naturellement à plus de deux centres.

Huff[3] a franchi cette limite en 1964 en remplaçant l'attractivité déterministe par une *probabilité de choix*. Dans le modèle de Huff, la probabilité qu'un consommateur situé en i choisisse le magasin j parmi un ensemble de J magasins dépend de deux composantes :

1. une mesure d'*attractivité* A_j du magasin j , fonction de ses caractéristiques (surface de vente, assortiment, image de marque).
2. une mesure de *frottement spatial* $f(d_{ij})$ décroissante de la distance ou du temps d'accès d_{ij} entre l'origine i et le magasin j .

La probabilité de choix s'écrit :

$$P_{ij} = \frac{A_j f(d_{ij})}{\sum_{k=1}^J A_k f(d_{ik})}. \quad (2.15)$$

L'attractivité A_j se spécifie habituellement comme une fonction de puissance de la surface de vente S_j : $A_j = S_j^\alpha$, avec $\alpha > 0$ mesurant la sensibilité à la taille du magasin. Le frottement spatial se paramètre le plus souvent par une fonction exponentielle décroissante : $f(d_{ij}) = \exp(-\beta d_{ij})$, avec $\beta > 0$ capturant la pénalisation de la distance. D'autres formulations (puissance inverse, $d_{ij}^{-\beta}$, piecewise, ou logistique) sont possibles selon la forme empirique observée.

Le modèle de Huff encode deux mécanismes économiques fondamentaux. Le premier est le *rendement d'échelle de l'attractivité* : un magasin plus grand exerce une attraction disproportionnée, car il offre un assortiment plus large, des économies d'échelle sur les prix, ou une expérience de shopping plus

riche. Le paramètre α mesure l'élasticité de la probabilité de choix par rapport à la surface. Le second mécanisme est le *décrochement spatial* : la probabilité de choix décroît avec la distance, reflétant le coût généralisé de l'accès (temps, carburant, inconfort). Le paramètre β contrôle la portée de la zone de chalandise : un β élevé concentre la demande près du magasin, un β faible l'étale sur une aire plus large.

La forme algébrique du modèle de Huff n'est pas un hasard : elle est un cas particulier du modèle logit multinomial. En posant :

$$V_{ij} = \ln(A_j) + \ln(f(d_{ij})) = \alpha \ln(S_j) - \beta d_{ij}, \quad (2.16)$$

la probabilité de Huff (Équation 2.15) devient exactement la probabilité logit :

$$P_{ij} = \frac{\exp(V_{ij})}{\sum_{k=1}^J \exp(V_{ik})}. \quad (2.17)$$

Le modèle de Huff est donc un MNL dans lequel l'utilité représentative V_{ij} dépend de deux seules variables, le logarithme de la surface de vente et la distance, avec des coefficients positifs (α) et négatifs ($-\beta$). Cette équivalence, bien que connue dans la littérature, est rarement soulignée dans les travaux appliqués en géographie commerciale, où les deux traditions (économétrie du choix discret et modélisation gravitaire) ont longtemps évolué en parallèle.

Cette identification a plusieurs conséquences importantes. D'abord, toutes les propriétés du MNL s'appliquent au modèle de Huff : convexité globale de la log-vraisemblance, identification par normalisation de l'échelle, propriété IIA. Deuxièmement, l'extension nichée du MNL s'applique au modèle de Huff. On peut par exemple structurer les magasins en groupes de formats ou d'enseignes pour atténuer l'IIA. Troisièmement, le cadre bayésien s'applique naturellement : les paramètres α et β deviennent des variables aléatoires dotées de distributions a priori, et l'inférence produit des distributions a posteriori qui quantifient l'incertitude sur les zones de chalandise prédites.

Du modèle de Huff au modèle bayésien hiérarchique. La limite principale du modèle de Huff classique est son caractère *global* : un seul couple (α, β) s'applique à l'ensemble de l'espace d'étude. Or, la sensibilité à la distance varie selon la densité urbaine, la disponibilité des transports, la culture locale de consommation. De même, l'effet de la surface diffère entre un centre commercial en périphérie et un magasin de centre-ville. Le cadre bayésien hiérarchique, présenté plus loin dans ce chapitre, permet de modéliser cette hétérogénéité spatiale en faisant varier les paramètres selon une distribution commune estimée à partir des données, plutôt qu'en les fixer uniformément.

2.3 Inférence bayésienne

Jusqu'à présent, nous avons présenté les modèles de choix discret et gravitaires dans un cadre fréquentiste, où les paramètres sont des quantités fixes inconnues estimées par maximum de vraisemblance. Le tournant bayésien consiste à traiter les paramètres eux-mêmes comme des variables aléatoires, dont l'incertitude est quantifiée par une distribution de probabilité mise à jour au fur et à mesure que les données informent les croyances initiales[10].

2.3.1 Théorème de Bayes et loi a posteriori

Le théorème de Bayes est l'opération centrale de l'inférence bayésienne[10]. Soit θ un vecteur de paramètres inconnus et y un jeu de données observé. Le théorème de Bayes s'écrit :

$$p(\theta | y) = \frac{p(y | \theta) p(\theta)}{p(y)} = \frac{p(y | \theta) p(\theta)}{\int p(y | \theta') p(\theta') d\theta'}, \quad (2.18)$$

où chaque terme porte un nom et une interprétation précis :

- $p(\theta)$ est la *distribution a priori*, qui encode les connaissances ou croyances sur θ avant l'observation des données,
- $p(y | \theta)$ est la *vraisemblance*, la probabilité des données étant donné les paramètres, identique à celle utilisée dans l'inférence fréquentiste,
- $p(\theta | y)$ est la *distribution a posteriori*, l'objet de l'inférence bayésienne, qui synthétise l'information apportée par les données et les croyances a priori,
- $p(y)$ est la *marginal* ou *Evidence*, une constante de normalisation qui ne dépend pas de θ .

Dans le contexte de nos modèles de choix discret, la vraisemblance $p(y | \theta)$ est le produit des probabilités logit (ou de Huff) des choix observés, tandis que les paramètres θ incluent les coefficients de l'utilité représentative (β , α , β_d) et éventuellement le paramètre d'échelle σ . Le théorème de Bayes transforme le problème d'estimation, trouver une valeur ponctuelle de θ , en un problème d'inférence distributionnelle, caractériser la distribution complète de θ étant donné les données.

Le choix des distributions a priori fait partie intégrante du théorème de Bayes : elles définissent l'information disponible avant les données et agissent comme une régularisation. Dans notre contexte, elles doivent rester faiblement informatives : assez larges pour laisser les données identifier les effets, mais assez structurées pour éviter des valeurs économiquement absurdes. Par exemple, les coefficients d'utilité liés aux caractéristiques des magasins peuvent recevoir des a priori normaux centrés autour de zéro, tandis que les paramètres strictement positifs, comme les écarts-types hiérarchiques ou certains paramètres de distance, sont mieux représentés par des lois positives telles que half-normal, log-normal ou gamma[10].

Cette logique est directement reliée au modèle de choix spatial. On sait avant estimation que la distance doit réduire l'utilité, que la surface ou l'attractivité commerciale doivent généralement l'augmenter, et que les effets locaux ne doivent pas varier sans limite entre zones. Les a priori permettent donc d'encoder ces contraintes souples sans imposer les résultats : l'a posteriori reste déterminé par la combinaison entre ces hypothèses initiales et l'information contenue dans les données.

Le cadre bayésien offre trois avantages décisifs pour le problème d'estimation de la demande potentielle dans une zone non observée.

Premièrement, la distribution a posteriori quantifie naturellement l'incertitude paramétrique. Plutôt qu'un estimateur ponctuel $\hat{\beta}$ accompagné d'un intervalle de confiance asymptotique (valide seulement pour de grands échantillons), le bayésien obtient une distribution a posteriori complète dont on extrait des intervalles crédibles exacts, même pour de petits échantillons. Pour la décision d'implantation, cette distinction est cruciale : savoir que le chiffre d'affaires attendu dans une zone candidate est de 2 millions d'euros avec un intervalle crédible [1.2, 3.1] est plus informatif qu'un point estimé de 2 millions accompagné d'un test d'hypothèse.

Deuxièmement, la prédiction bayésienne intègre automatiquement l'incertitude paramétrique[10]. La distribution prédictive pour une observation future y_{fut} dans une zone g s'obtient en intégrant sur la distribution a posteriori :

$$p(y_{\text{fut}} | y) = \int p(y_{\text{fut}} | \theta) p(\theta | y) d\theta. \quad (2.19)$$

Cette intégrale, appelée *distribution prédictive a posteriori*, élargit naturellement l'incertitude prédictive pour tenir compte de l'incertitude sur les paramètres. Un modèle fréquentiste qui utiliserait $\hat{\theta}$ au lieu de $p(\theta | y)$ sous-estimerait systématiquement l'incertitude.

Troisièmement, le cadre bayésien permet d'incorporer de manière cohérente des connaissances expertes via les distributions a priori. Dans un contexte où les données historiques peuvent être limitées pour certains formats ou certaines zones géographiques, un a priori informatif fondé sur des études antérieures ou l'expérience métier stabilise les estimates sans les imposer de manière dogmatique.

2.3.2 Optimisation et inférence variationnelle

Dans ce projet, l'estimation n'est pas principalement utilisée comme une recherche d'un unique jeu de paramètres optimal. Le modèle doit produire des distributions de revenus plausibles, donc propager l'incertitude des paramètres vers les prédictions. Pour cette raison, le maximum a posteriori (MAP) et L-BFGS sont conservés comme outils de stabilisation et de diagnostic rapide, tandis que l'inférence variationnelle automatique (ADVI) constitue le moteur principal de l'estimation[11, 12, 13].




Figure 2.1 : Comparaison des méthodes d'inférence : MAP, MCMC et ADVI.

MAP et L-BFGS : un point d'ancrage rapide

Soit θ le vecteur des paramètres et

$$h(\theta) = \log p(y | \theta) + \log p(\theta) \quad (2.20)$$

le log-postérieur non normalisé. Le maximum a posteriori est défini par

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} h(\theta). \quad (2.21)$$

Il correspond au mode de la distribution a posteriori[10]. Par rapport à un maximum de vraisemblance classique, le terme $\log p(\theta)$ introduit la régularisation apportée par les a priori.

Pour calculer ce point, on utilise une méthode d'optimisation de type quasi-Newton. La méthode de Newton-Raphson s'appuie sur le gradient $\nabla h(\theta)$ et sur la hessienne $\nabla^2 h(\theta)$ pour adapter la direction et la taille du pas. L'idée est simple : le gradient indique dans quelle direction améliorer l'objectif, tandis que la courbure locale indique si l'on peut avancer fortement ou s'il faut faire un pas plus prudent. En pratique, calculer et inverser la hessienne complète devient coûteux lorsque le nombre de paramètres augmente. L-BFGS contourne cette difficulté en gardant seulement une mémoire limitée des dernières variations de paramètres et de gradients ; il approxime ainsi l'information de courbure sans stocker la matrice hessienne complète[11].

Dans notre pipeline, le MAP sert donc surtout à vérifier que la spécification est numériquement cohérente : ordre de grandeur des effets, signes des coefficients, absence de divergence évidente. Il ne suffit pas pour le résultat final, car il ne fournit qu'un point. Il ne décrit ni l'incertitude, ni les corrélations entre paramètres, ni la variabilité des prédictions. Ces limites motivent le recours à l'inférence variationnelle.

Principe de l'inférence variationnelle

L'inférence bayésienne vise à caractériser la distribution a posteriori

$$p(\theta | y) = \frac{p(y, \theta)}{p(y)}. \quad (2.22)$$

Dans les modèles complexes, cette distribution est rarement disponible sous forme analytique, car le terme de normalisation $p(y)$ implique une intégrale de grande dimension. Les méthodes MCMC contournent ce problème en simulant des échantillons asymptotiquement distribués selon le posterior, mais elles peuvent être coûteuses sur des modèles hiérarchiques et géospatiaux de grande taille.

L'inférence variationnelle propose une autre stratégie : transformer l'inférence en problème d'optimisation [12]. Au lieu d'échantillonner directement le posterior exact, on choisit une famille de distributions plus simple $q_\phi(\theta)$, indexée par des paramètres variationnels ϕ , puis on cherche dans cette famille la distribution la plus proche du posterior. Autrement dit, l'objectif est de remplacer une distribution difficile à manipuler par une approximation contrôlée, suffisamment précise pour l'analyse et beaucoup plus rapide à obtenir.

La proximité entre $q_\phi(\theta)$ et $p(\theta | y)$ est mesurée par la divergence de Kullback-Leibler :

$$\text{KL}(q_\phi(\theta) \parallel p(\theta | y)). \quad (2.23)$$

Minimiser directement cette quantité n'est pas possible, car elle dépend du posterior normalisé. On maximise donc une quantité équivalente appelée *Evidence Lower Bound* (ELBO)[12] :

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi(\theta)} [\log p(y, \theta) - \log q_\phi(\theta)]. \quad (2.24)$$

L'ELBO est une borne inférieure de $\log p(y)$. La maximiser revient à rapprocher l'approximation variationnelle du posterior. Le premier terme favorise les valeurs de paramètres qui expliquent bien les données et respectent les a priori ; le second terme empêche l'approximation de devenir artificiellement trop concentrée.

Cette approche est particulièrement adaptée à notre contexte. Le modèle contient plusieurs familles de paramètres : attractivités par format, frictions de distance, effets de surface, effets démographiques, capacité de dépense et paramètres de vraisemblance. L'inférence variationnelle permet d'obtenir rapi-

dement une distribution approximative pour ces paramètres, puis de générer des prédictions de chiffre d'affaires avec intervalles d'incertitude.

Autodifférentiation : calcul automatique des gradients

Pour optimiser l'ELBO, il faut calculer ses gradients par rapport aux paramètres variationnels. Dans un modèle simple, ces dérivées pourraient être obtenues à la main. Dans notre cas, ce serait peu réaliste : le modèle combine des transformations logarithmiques, des probabilités de choix, des agrégations spatiales, des priors contraints et une vraisemblance robuste.

L'autodifférentiation répond à ce problème[14]. Elle ne doit pas être confondue avec la différentiation numérique par différences finies, qui approxime une dérivée en perturbant légèrement les paramètres, ni avec la dérivation symbolique complète, qui manipule des expressions algébriques parfois très longues. L'autodifférentiation décompose simplement le calcul en opérations élémentaires : additions, multiplications, exponentielles, logarithmes, sommes et produits. Chaque opération possède une dérivée connue. En appliquant automatiquement la règle de la chaîne le long du graphe de calcul, le logiciel obtient des gradients précis à la machine.

Dans PyMC, ce rôle est assuré par PyTensor[15]. Le modèle probabiliste est représenté comme un graphe de calcul : les nœuds correspondent aux opérations et les arêtes aux dépendances entre variables. Le même graphe permet d'évaluer le log-joint $\log p(y, \theta)$ et de calculer automatiquement les gradients nécessaires à L-BFGS et à ADVI. Cette automatisation est importante pour le workflow : elle évite de dériver manuellement un nouvel algorithme à chaque modification du modèle.

ADVI : automatiser l'inférence variationnelle

L'Automatic Differentiation Variational Inference (ADVI), proposé par Kucukelbir *et al.*[13], automatise l'inférence variationnelle pour une large classe de modèles probabilistes différentiables. L'idée centrale est de séparer le travail en trois étapes génériques : transformer les variables contraintes vers un espace réel non contraint, poser une approximation variationnelle simple dans cet espace, puis optimiser l'ELBO à l'aide de gradients calculés automatiquement.

La première étape consiste à transformer les paramètres du modèle. Beaucoup de paramètres bayésiens vivent sur des domaines contraints : un écart-type doit être positif, une probabilité doit être comprise entre 0 et 1, un paramètre de corrélation doit respecter des contraintes de matrice. ADVI applique des transformations différentiables pour envoyer toutes ces variables dans un espace commun $\mathbb{R}^K$. Si l'on note ζ les paramètres transformés, le modèle est réécrit dans cet espace non contraint avec le terme jacobien correspondant. Cette étape permet d'utiliser ensuite une même forme d'approximation, indépendamment des contraintes initiales.

La deuxième étape consiste à choisir une famille variationnelle. Dans la version *mean-field*, ADVI utilise une gaussienne factorisée :

$$q_\phi(\zeta) = \mathcal{N}(\zeta \mid \mu, \text{diag}(\sigma^2)), \quad (2.25)$$

où $\phi = (\mu, \sigma)$ regroupe les paramètres variationnels. Le vecteur μ donne la position moyenne de l'approximation, tandis que σ mesure l'incertitude marginale associée à chaque coordonnée transformée. Cette approximation est rapide et adaptée au passage à l'échelle, mais elle suppose que les coordonnées sont indépendantes dans l'espace transformé. Une version *full-rank* peut représenter les corrélations, mais elle est plus coûteuse en mémoire et en temps de calcul.

La troisième étape est l’optimisation de l’ELBO. ADVI utilise la reparamétrisation gaussienne : au lieu de tirer directement ζ depuis q_ϕ , on écrit

$$\zeta = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (2.26)$$

L’aléa est alors porté par ϵ , qui ne dépend pas de ϕ . Cette écriture rend l’objectif différentiable par rapport à μ et σ . PyTensor peut donc calculer les gradients de l’ELBO par autodifférentiation.

Rôle de Monte Carlo dans ADVI

L’ELBO contient une espérance sous la distribution variationnelle. Cette espérance n’est généralement pas calculable exactement. ADVI l’approxime donc par Monte Carlo[13] : à chaque itération, l’algorithme tire quelques valeurs de ϵ , transforme ces valeurs en paramètres ζ , évalue le log-joint corrigé, puis estime un gradient de l’ELBO. Ce gradient est bruité, car il dépend d’un nombre fini de tirages, mais il est suffisamment informatif pour guider une optimisation stochastique.

L’intuition est la suivante. À chaque itération, ADVI teste quelques configurations plausibles des paramètres selon l’approximation courante. Si ces configurations expliquent mal les données, le gradient déplace μ et σ vers des régions plus plausibles. Si l’approximation est trop étroite ou trop large, le terme d’entropie de l’ELBO ajuste également les écarts-types variationnels. En répétant ce processus, l’approximation q_ϕ se rapproche progressivement du posterior.

Dans notre implémentation, le nombre de tirages Monte Carlo par itération est volontairement faible afin de garder un temps de calcul raisonnable, mais supérieur à un tirage unique pour réduire le bruit du gradient. Le suivi de l’ELBO permet ensuite de vérifier que ce bruit reste contrôlé : une courbe qui atteint un plateau indique que les mises à jour stochastiques se stabilisent autour d’une région optimale.

Choix méthodologique dans ce projet

Le choix d’ADVI est donc pragmatique. Le modèle est trop riche pour que le MAP suffise, car la décision d’implantation exige des intervalles crédibles et des simulations prédictives a posteriori. Une inférence MCMC complète serait plus fidèle asymptotiquement, mais coûteuse pour tester rapidement plusieurs variantes de vraisemblance et plusieurs spécifications de l’utilité. ADVI offre un compromis adapté : il fournit une approximation distributionnelle du posterior, suffisamment rapide pour itérer, comparer les modèles et propager l’incertitude vers les revenus prédits.

Ce choix impose néanmoins une vigilance méthodologique. Une approximation variationnelle gaussienne, surtout en mean-field, peut sous-estimer certaines corrélations ou certaines queues du posterior. C’est pourquoi les résultats ne sont pas interprétés uniquement à partir de l’ELBO ou des paramètres moyens. Ils sont évalués par contrôle prédictif a posteriori, validation hors-échantillon et analyse de couverture des intervalles HDI. Dans ce travail, ADVI est donc l’outil principal d’estimation, mais le workflow bayésien reste le cadre qui permet d’en contrôler les limites.

2.4 Conclusion

Ce chapitre a posé les fondements théoriques du modèle de choix spatial bayésien que nous mobilisons. Le premier pilier est la théorie de l’utilité aléatoire et des modèles de choix discrets, qui fournit le

langage formel pour modéliser le comportement de sélection d'un point de vente parmi un ensemble d'alternatives concurrentes. Le modèle logit multinomial et le modèle de Huff en sont les formulations les plus utiles pour notre application, offrant un compromis entre réalisme comportemental et faisabilité computationnelle.

Le deuxième pilier est hiérarchique : il permet le partage d'information entre zones géographiques et formats commerciaux, ce qui est essentiel pour prédire des revenus dans des territoires partiellement observés. Le troisième pilier est bayésien : les paramètres ne sont pas réduits à des valeurs fixes, mais traités comme des variables incertaines dont la distribution a posteriori doit être approximée. Dans ce cadre, le MAP et L-BFGS jouent un rôle de diagnostic rapide, tandis qu'ADVI constitue l'outil principal pour obtenir une approximation distributionnelle du posterior et propager l'incertitude vers les revenus prédits.

Enfin, le pilier computationnel rend cette estimation opérationnelle. L'autodifférentiation, via Py-Tensor, calcule automatiquement les gradients du log-joint et de l'ELBO. ADVI exploite ces gradients et des estimations Monte Carlo pour optimiser une approximation variationnelle rapide. Cette combinaison permet de tester plusieurs spécifications du modèle sans abandonner la logique probabiliste nécessaire à l'aide à la décision.

Le chapitre suivant expose l'ingénierie des données qui alimente ce cadre théorique : la construction de la grille spatiale, l'ingestion des sources hétérogènes, le calcul des indicateurs géospatiaux et la conception de la couche analytique reliant les données brutes au modèle structurel.

Architecture des données et couche analytique

Introduction

La qualité des données constitue le plancher de toute performance prédictive, indépendamment de la sophistication du modèle statistique mobilisé. Dans un projet de prédiction spatiale du choix de magasin, cette assertion prend une acuité particulière : chaque observation est ancrée dans l'espace géographique marocain, chaque variable porte la marque d'une source hétérogène, et chaque jointure spatiale introduit des risques de perte d'information ou de biais de couverture. Le présent chapitre documente rigoureusement l'ensemble de la chaîne de valeur de la donnée : acquisition multi-source, traitement, enrichissement, validation, stockage et mise à disposition. Nous ne traitons ici ni de la spécification du modèle de choix, réservée au chapitre suivant, ni de l'interprétation des résultats, mais exclusivement de l'ingénierie de la donnée au sens plein.

Cinq familles de données sont mobilisées, chacune répondant à une question fonctionnelle distincte. Les données démographiques et de population, issues de la grille GHS-POP 2025 calibrée par les données du Haut-Commissariat au Plan (HCP[16]), caractérisent la demande résidentielle à l'échelle sub-kilométrique. Les données géospatiales des points de vente propres à Label'Vie, incluant surface de vente, format commercial, chiffre d'affaires observé, ancienneté et indicateurs d'offre, caractérisent l'offre propre. Les données concurrentielles, collectées par scraping de l'API Places de Google Maps[17], rendent compte de l'offre adverse. Les données de mobilité, tirées du réseau routier OpenStreetMap[18] et routées via OSRM[19], capturent les frictions de déplacement entre chaque cellule de population et chaque point de vente. Enfin, les données socio-économiques issues du recensement HCP et d'un indice de richesse construit ex post caractérisent le pouvoir d'achat territorial.

Ces cinq familles ne se combinent pas de manière triviale. Chaque source présente un système de référence, une granularité et un format propres. L'interopérabilité entre elles, leur intégration dans une architecture cohérente reposant sur un identifiant spatial commun et un système de projection unique, constitue en elle-même un défi d'ingénierie non trivial. Nous exposons cette chaîne de valeur selon une progression logique : définition de la maille spatiale, acquisition et traitement des sources, conception des flux ETL/ELT, construction des indicateurs géospatiaux, puis gouvernance de la couche analytique. L'implémentation détaillée de chaque étape du pipeline est consultable dans le dépôt GitHub du projet en annexe.

3.1 Définition de la grille spatiale élémentaire

3.1.1 Choix de la maille spatiale

La source de données la plus fondamentale de notre architecture est la grille GHS-POP (Global Human Settlement Population), publiée par le Centre Commun de Recherche (Joint Research Centre) de la Commission Européenne[20]. Il s'agit d'une grille mondiale à résolution de $100\text{ m} \times 100\text{ m}$, produite par modélisation statistique à partir de données de recensement nationales, d'imagerie satellitaire Sentinel-2 et de données bâties issues du programme GHSL (Global Human Settlement Layer). Chaque cellule de cette grille porte une estimation de la population résidente, notée DN dans notre jeu de données.

Le programme GHSL opère à partir des données de recensement nationales, qui fournissent les totaux de population par unité administrative et l'imagerie satellitaire à haute résolution. La population est ensuite allouée aux cellules de grille par proportionnalité à la surface bâtie détectée dans chaque cellule, sous la contrainte que le total par unité administrative corresponde au chiffre officiel de recensement. Cette méthode, bien que sophistiquée, introduit une source d'erreur systématique : l'interpolation spatiale peut attribuer une population non nulle à des cellules qui ne contiennent en réalité aucun bâtiment, notamment en périphérie des zones urbaines où la résolution de l'imagerie est insuffisante pour distinguer les petites emprises bâties.

La cellule élémentaire est un carré de $100\text{ m} \times 100\text{ m}$, identifié par l'indice de son centroïde, un entier unique non séquentiel, hérité de l'indexation originale de la grille GHS. Notre jeu de données final comporte 282 113 cellules au total. La variable DN présente une distribution fortement asymétrique, comme le montre la figure 3.1 : sa médiane est de 23 habitants, son maximum atteint 3 601 habitants, et sa moyenne s'élève à 67,8 habitants par cellule. Seules 474 cellules sur 282 113 ont une valeur nulle, correspondant à des zones effectivement non peuplées. Cette asymétrie reflète la concentration de la population marocaine dans les zones urbaines.




Figure 3.1 : Distribution de la population par cellule de grille GHS-POP (100 m). La médiane (23 habitants) est nettement inférieure à la moyenne (67,8), témoignant de la concentration urbaine.




Figure 3.2 : Illustration de la grille GHS appliquée à Casablanca. À gauche, la décomposition large de la ville en cellules GHS. À droite, un zoom local montrant un quartier décomposé et le centroïde matérialisé par une étoile jaune.

Chaque cellule porte également un `code_commune`, attribué par jointure spatiale point-polygone entre le centroïde de la cellule et les limites administratives des communes. Sur les 1 561 communes, seules 428 sont actives dans notre périmètre d'étude, c'est-à-dire qu'elles contiennent au moins une cellule de grille peuplée accessible à un magasin. Cette réduction de 1 561 à 428 communes reflète la concentration du réseau commercial dans les agglomérations principales.

3.1.2 Critères de découpage et contraintes opérationnelles

Le système de référence de coordonnées retenu pour l'ensemble du projet est EPSG :32629[21], correspondant à la projection UTM zone 29N. Ce choix n'est pas arbitraire : la zone 29N couvre l'ensemble du territoire marocain en coordonnées métriques planes. La projection UTM (Universal Transverse Mercator) divise la Terre en 60 fuseaux de 6 degrés de longitude chacun. Le fuseau 29N, centré sur le méridien 9° Ouest, englobe le Maroc dans son intégralité. La propriété d'isométrie locale de la projection UTM garantit que les calculs de distance euclidienne en mètres sont corrects à l'échelle intra-urbaine, avec une erreur inférieure à 0,1 % pour des distances inférieures à 50 km du méridien central de la zone. Cette propriété est indispensable pour le calcul des matrices de distance grille-magasin et l'interprétation des coefficients de sensibilité à la distance dans le modèle de choix.

La calibration de la grille GHS-POP par les données du Haut-Commissariat au Plan (HCP[16]) du Maroc est une étape essentielle. Les totaux de population par commune issus du recensement marocain ont été utilisés pour recalibrer les valeurs absolues de la grille GHS, qui peut présenter des biais systématiques dans les pays à faible couverture de recensement. Toutefois, cette calibration ne résout pas entièrement le problème des « grilles fantômes, cellules dont la valeur DN est non nulle en l'absence de tout bâti au sol, un artefact de l'interpolation spatiale sous-jacente à la construction de la grille GHS.

3.1.3 Implications pour la modélisation et l'interprétation

Malgré la calibration HCP, certaines cellules de la grille présentaient des valeurs de population non nulles en l'absence de tout bâti, phénomène dû à l'interpolation spatiale sous-jacente à la construction de la grille GHS. Ces grilles fantômes auraient introduit des unités de demande fictives dans le modèle, biaisant les probabilités de choix et les estimations de chiffre d'affaires. La solution adoptée est une segmentation sémantique des bâtiments à l'échelle nationale, conduite via le modèle SAM3 (Segment

Anything Model v3) de Meta AI[22].

SAM est un modèle de fondation entraîné sur des millions d’images, capable de segmenter tout objet visuel à partir d’un prompt minimal. Son application à l’imagerie satellitaire à haute résolution permet d’identifier les emprises bâties au sol avec une précision supérieure aux couches vectorielles ouvertes telles que OpenStreetMap, dont la couverture est hétérogène au Maroc. L’avantage de SAM par rapport aux méthodes traditionnelles de classification d’images, telles que les réseaux de type U-Net entraînés sur des données spécifiques, réside dans sa capacité zero-shot : il n’est pas nécessaire de lui fournir un jeu d’entraînement spécifique à la segmentation des bâtiments, ce qui réduit considérablement le coût de mise en oeuvre à l’échelle nationale.

Le pipeline d’inférence SAM procède en quatre étapes. L’ingestion d’imagerie satellitaire à haute résolution est réalisée par téléchargement de tuiles via ESRI World Imagery[23]. La construction d’une mosaïque de tuiles pour un bounding box donné les stitch en une image unique, géoréférencée dans un GeoTIFF en EPSG 3857 avec un niveau de zoom typiquement fixé à 17 pour une résolution d’environ 1,5 mètre par pixel. Le découpage en tuiles compatibles avec la fenêtre de contexte de SAM permet de traiter des zones urbaines étendues. L’inférence de segmentation extrait les polygones bâtis : sur 57 000 tuiles, plus d’un million de polygones de bâtiment ont été extraits sur l’ensemble du royaume. La jointure spatiale entre les polygones bâtis et les cellules de la grille GHS identifie les cellules effectivement peuplées. Seules les cellules dont le centroïde intersecte un polygone bâti sont retenues comme grilles actives dans le jeu de données final.




Figure 3.3 : Exemple de sortie du pipeline de segmentation SAM3. L’image de gauche montre l’imagerie satellitaire à haute résolution avant traitement. L’image de droite illustre les polygones de bâtiments segmentés automatiquement par le modèle SAM3 de Meta AI.

3.2 Panorama des sources de données

3.2.1 Données internes de l’enseigne

Les données internes portant sur les magasins du groupe constituent la source la plus riche en attributs. 1 957 points de vente répartis en cinq formats commerciaux, *Discounter*, *Market*, *Proxi*, *Hyper* et *Hypercash*, et différentes marques : *Kazyon*, *LabelVie*, *BIM*, *Marjane*, *Hyper U*, *Aswak Salam*. La répartition par format reflète la stratégie de couverture du marché marocain : le format *Discounter* cible la proximité à prix réduit, le format *Market* cible les achats hebdomadaires en grande surface, le format *Proxi* cible les achats de convenance à haute fréquence, et les formats *Hyper* et *Hypercash* ciblent une grande échelle de population pour différents achats alimentaires et non alimentaires.

La distribution des surfaces de vente par format est présentée dans la figure 3.4. La surface de vente (**Surface**), exprimée en mètres carrés, présente une distribution concentrée sur les petits formats : la médiane est de 255 m², le minimum de 104 m², et le maximum de 15 714 m², avec une moyenne de 883 m². Cette concentration sur les petits formats est cohérente avec la prédominance des formats Discounter et Proxi dans le réseau.




Figure 3.4 : Distribution de la surface de vente par format commercial. La médiane globale (255 m²) reflète la prédominance des formats Discounter et Proxi.

Chaque magasin est caractérisé par les attributs suivants. Le code magasin (**Shop code**) est un identifiant string unique. La marque (**Brand**) et le format commercial (**Cluster**) permettent de distinguer les stratégies d'offre. Le concept architectural (**Shop concept**) capture les variations de tarification à l'intérieur d'un même format. La commune permet l'ancrage géographique. La disponibilité du rayon d'alcool (**Rayon alcool**) constitue un indicateur d'attractivité codé en valeurs booléennes. La présence du rayon alcool peut augmenter le chiffre d'affaires de plus de 20 %.

3.2.2 Données de mobilité et de fréquentation

La matrice `distance_grid_store` constitue la pièce maîtresse de l'architecture. Elle établit, pour chaque paire (`centroid_idx`, `Shop code`), la distance à pied en mètres (`distance_m_walk`) et le temps de trajet en voiture en secondes (`duration_s_drive`).

Le calcul des distances est réalisé via un service de routage OSRM (Open Source Routing Machine)[19]. Deux profils de routage sont interrogés : un profil pédestre pour les distances à pied et un profil motorisé pour les distances en voiture. Le calcul s'effectue par un routage parallélisé sur les paires valides. Le post-filtrage par distance est une optimisation nécessaire : sans lui, le nombre de requêtes de routage serait de l'ordre de $282\,000 \times 1\,957 \approx 551$ millions, ce qui est computationnellement prohibitif. Avec le pré-filtrage à 8 km (EPSG :32629), seul un sous-ensemble restreint de paires est soumis au routage complet.

La distribution des distances avant filtrage métier est illustrée par la figure 3.5. La cardinalité brute est de 7 894 633 paires. Parmi elles, 55 971 paires ont une distance pédestre manquante, indication de non-accessibilité à pied. La distance moyenne à pied est de 53 km, avec une médiane de 14,5 km et un maximum de 640 km. Le temps de conduite moyen est de 2 971 secondes (environ 50 minutes), avec une médiane de 1 027 secondes (17 minutes). Conserver directement ces 7,9 millions de paires dans le

modèle serait économiquement incohérent : un consommateur ne considère pas de manière réaliste un magasin situé à plusieurs dizaines de minutes en voiture, ou très éloigné à pied, comme une alternative effective dans son ensemble de choix.

Le pré-filtrage initial à 8 km en distance euclidienne, calculée en EPSG :32629, joue uniquement un rôle computationnel. Il réduit le nombre de paires à router, mais ne garantit pas que la distance réellement parcourue sur le réseau soit inférieure à 8 km. Une cellule peut être proche d'un magasin en ligne droite tout en étant beaucoup plus éloignée en distance pédestre ou routière, par exemple en raison d'une discontinuité du réseau piéton, d'une barrière physique, d'une voie rapide, d'un oued ou d'un détour imposé par la structure urbaine. Le buffer euclidien constitue donc une approximation géométrique, non une définition économique de l'accessibilité.

Pour cette raison, un second filtrage est appliqué après routage OSRM, cette fois à partir de seuils métier propres à chaque format commercial. Pour les magasins **Discounter**, l'ensemble de choix est limité à une accessibilité pédestre maximale de 7 minutes. Pour les magasins **Proxi**, le seuil est porté à 10 minutes à pied. Les formats **Market** sont filtrés sur un temps de conduite maximal de 10 minutes, tandis que les formats **Hyper** et **Hypercash** sont retenus jusqu'à 18 minutes en voiture. Lorsque la métrique pédestre OSRM est exprimée sous forme de durée, une correction est appliquée afin de convertir cette durée en distance équivalente : une seconde de marche OSRM correspond empiriquement à 1,44 seconde dans notre échelle de référence, ce qui conduit à réduire la distance admissible avant filtrage. Ce filtrage métier transforme ainsi la matrice brute de distances en un espace de choix économiquement plausible, adapté aux comportements d'accès différenciés par format.




Figure 3.5 : Distribution des distances grille-magasin. L'écart moyenne-médiane témoigne de la présence de paires à longue distance (zones rurales).

3.2.3 Données cartographiques et réseau

Les données du réseau routier proviennent d'OpenStreetMap[18], interrogé pour construire les graphes de routage utilisés par OSRM. Le réseau OSM fournit les segments routiers, leurs attributs (nombre de voies, type de voirie, sens unique, longueur), et les nœuds de connexion. Ces données sont la base du calcul des plus courts chemins entre chaque cellule de grille et chaque magasin.

Les points d'intérêt (POIs) sont collectés via deux sources complémentaires. La source Google Maps fournit un catalogue large de commerces et services de proximité. La source TomTom POI API[24] offre une taxonomie plus structurée avec des codes de catégorie hiérarchisés. L'API TomTom est interrogée avec un rayon de 10 km autour de chaque centre de ville cible, avec pagination (limite de 100 résultats par requête) et un délai entre les requêtes pour respecter les quotas.

La figure 3.6 présente la répartition des 39 044 entrées de POIs collectées, réparties en douze types :

bus, taxi, tram, train, poste, health, pharmacy, school, hotel, mosquée, fashion et administration. Chaque entrée associe un `centroid_idx` à un `POI_type` et un compteur `count`, le nombre de POIs de ce type dans le rayon défini autour de la cellule.




Figure 3.6 : Répartition des points d'intérêt par catégorie. Les POIs de transport (bus, taxi, tram) dominent, suivis des services (pharmacy, school, mosquée).

3.2.4 Données démographiques et socio-économiques

L'enrichissement démographique s'opère à l'échelle communale à partir de plusieurs variables issues du recensement du Haut-Commissariat au Plan (HCP). Dans le cadre de cette modélisation, nous mobilisons l'ensemble des indicateurs socio-démographiques disponibles, tout en accordant une attention particulière aux structures de population féminine, qui se révèlent empiriquement plus informatives pour expliquer les dynamiques de fréquentation et de consommation observées dans les formats de retail moderne étudiés.

Les variables démographiques communales intégrées sont le taux d'éducation féminine, le taux de femmes sans instruction, la taille moyenne des ménages, la proportion de propriétaires, et la proportion de femmes employées dans le secteur privé. Ces variables proviennent du recensement HCP et sont normalisées selon la transformation Z-score variable par variable.

Un indice de pouvoir d'achat est calculé pour chaque grille à partir de données socio-économiques infracommunales construites ex post par analyse immobilière. L'indice brut est normalisé selon la transformation Z-score. Pour les grilles dont l'indice est manquant, on impute la médiane nationale, puis on réapplique la normalisation. Cette variable joue un double rôle dans le modèle : elle module l'attractivité des magasins du côté de l'utilité et sert d'indicateur territorial du potentiel de dépense.

3.2.5 Données concurrentielles

Les enseignes concurrentes, Marjane, BIM, Kazyon et d'autres acteurs de la grande distribution marocaine, ont été collectées par trois canaux complémentaires. Le premier canal est le scraping de l'API Places de Google Maps[17], réalisé de manière concurrente. La stratégie consiste en une couverture systématique des zones urbaines du Maroc par une grille de requêtes géolocalisées, avec déduplication des résultats par identifiant Place Google et filtrage par catégorie de commerce. L'approche par grille garantit que chaque zone urbaine est couverte de manière uniforme, sans biais de couverture lié à la

notoriété de l'enseigne.

En utilisant Selenium, une bibliothèque Python qui mime le comportement humain de navigation web, le script interroge Google Maps avec des mots-clés de chaque concurrent associés à un code postal et une adresse, puis extrait les coordonnées de latitude et longitude. Les résultats sont stockés dans un fichier Parquet avec les attributs suivants : nom du lieu, catégorie, adresse, ville, latitude, longitude, et horaires d'ouverture.

Les attributs collectés par les canaux Google Maps et web scraping comprennent le nom, la géolocalisation (latitude/longitude), la catégorie et les horaires d'ouverture. Ces données sont intégrées dans le jeu de magasins global : chaque concurrent constitue une alternative au sens du modèle de choix discret. La géolocalisation est projetée du système WGS84 (EPSG :4326) vers le système UTM zone 29N (EPSG :32629) pour garantir la cohérence avec le reste de l'architecture.

Une limite méthodologique importante mérite d'être soulignée : la surface de vente des concurrents n'est généralement pas disponible via l'API Google Maps ni par les canaux de web scraping. Des règles de remplacement par surface médiane de format ont été appliquées. Cette imputation introduit un bruit dans la variable d'attractivité associée à la surface, mais ce bruit est atténué par la nature hiérarchique du modèle, les effets de format étant estimés par pooling partiel, ce qui régularise les estimations pour les magasins dont les attributs sont imputés.

3.3 Conception des flux de données ETL

3.3.1 Ingestion et standardisation des sources

Les sources brutes documentées ci-dessus ne sont pas directement exploitables par le modèle bayésien de choix discret. Avant l'estimation, chaque variable subit une série de transformations, filtrage, indexation, normalisation, transformation fonctionnelle, dont l'objectif est triple : rendre les grandeurs comparables d'une source à l'autre, respecter les propriétés fonctionnelles du modèle (forme gravitaire, utilité linéaire dans les paramètres), et garantir la stabilité numérique de l'inférence.

La première étape consiste à restreindre l'univers des magasins à ceux pour lesquels on dispose d'un chiffre d'affaires annuel observable et stabilisé. Sont retenus les magasins de l'enseigne Label'Ve pour lesquels le chiffre d'affaires est disponible sur la période avril 2025 à avril 2026. Les magasins ouverts depuis moins de douze mois sont exclus : leur revenu n'est pas encore stabilisé et présente une dynamique de montée en puissance qui biaiserait les estimations d'attractivité structurelle. Les magasins concurrents ne sont pas inclus à cette étape : leur revenu individuel est inobservé. Seule la masse totale des dépenses alimentaires par commune, issue de l'enquête HCP 2025, sera utilisée comme contrainte macroéconomique agrégée.

Du côté de la demande, seules les cellules de grille g vérifiant $N_g > 0$ sont conservées, où N_g désigne la population estimée de la cellule (variable DN). Chaque grille retenue se voit attribuer un identifiant entier unique, indexé de 0 à $N_{\text{grids}} - 1$. De même, chaque magasin reçoit un identifiant entier s , indexé de 0 à $N_{\text{stores}} - 1$. Cette indexation est une condition nécessaire à la représentation matricielle et tensorielle du modèle.

3.3.2 Géocodage et enrichissement spatial

L'espace de choix effectif est l'ensemble $\mathcal{P}$ des paires (g, s) satisfaisant les seuils de distance définis précédemment. La cardinalité de cet ensemble, notée N_{pairs} , est de l'ordre de plusieurs millions, bien inférieure au produit cartésien complet $N_{\text{grids}} \times N_{\text{stores}}$, mais suffisante pour couvrir les interactions économiquement pertinentes.

On construit deux vecteurs d'index de longueur N_{pairs} : le vecteur **gidx**, qui associe à chaque paire l'identifiant de sa grille, et le vecteur **sidx**, qui associe à chaque paire l'identifiant de son magasin. Formellement, pour la i -ème paire du jeu de données, on a **gidx**[i] = g_i et **sidx**[i] = s_i . Cette représentation éparse évite le produit cartésien complet : seules les interactions vérifiant les seuils de distance sont conservées, ce qui réduit drastiquement la dimensionnalité du problème inférentiel et la consommation mémoire associée.

Chaque paire porte en outre l'indice de format du magasin, noté **pair_format_idx**[i] = $f(s_i)$, où $f(s) \in \{\text{Discounter, Proxi, Market, Hyper, HyperCash}\}$ désigne le format commercial du magasin s . Cet indice permet d'agréger les probabilités de choix par format sans jointure supplémentaire.

3.4 Construction des indicateurs géospatiaux

Mesure de l'accessibilité

Les mesures brutes d'accessibilité sont d'abord ramenées à des unités interprétables avant transformation : la distance à pied d_{gs}^{walk} , initialement exprimée en mètres, est convertie en kilomètres, tandis que la durée de conduite t_{gs}^{drive} , initialement exprimée en secondes, est convertie en minutes. Une borne minimale est ensuite appliquée afin d'éviter les valeurs nulles ou quasi nulles avant passage au logarithme : 50 mètres pour la marche, soit 0,05 km, et 1 minute pour la conduite.

$$\tilde{d}_{gs}^{\text{walk}} = \log(\max(d_{gs}^{\text{walk}}/1000, 0,05)), \quad \tilde{t}_{gs}^{\text{drive}} = \log(\max(t_{gs}^{\text{drive}}/60, 1)). \quad (3.1)$$

Ce prétraitement produit les variables **log_walk** et **log_drive** utilisées par le modèle. Le changement d'unité est important : des kilomètres et des minutes sont directement interprétables économiquement, contrairement aux mètres et aux secondes, et donnent une échelle plus naturelle aux coefficients et aux lois a priori du modèle de choix multinomial. La transformation logarithmique conserve l'idée d'une sensibilité décroissante à l'éloignement : l'écart perçu entre 1 et 2 km est plus important que l'écart entre 20 et 21 km. Elle stabilise également la dynamique numérique des variables, tout en laissant au modèle la possibilité d'apprendre des effets d'accessibilité différenciés selon les formats commerciaux. La spécification détaillée de ces effets et de leurs priors est présentée dans le chapitre de modélisation.

Densité de population et structure urbaine

Le vecteur population $\mathbf{N} = (N_0, \dots, N_{N_{\text{grids}}-1})$ est constitué directement à partir de la variable DN de la grille GHS, après filtrage des cellules actives.

Le pipeline construit une variable dérivée, **log_store_pop**, qui n'existe dans aucune source brute mais résulte d'une agrégation spatiale : pour chaque magasin, la population maximale parmi toutes les grilles qui lui sont associées est calculée, puis transformée en logarithme. Cette variable capture l'effet de « population captive d'un magasin : un magasin situé à proximité d'une grille à forte population

bénéficie d'un avantage d'attractivité indépendant de sa surface ou de son format. Cette variable est normalisée selon la transformation Z-score avant d'être intégrée au modèle.

Zones de chalandise

Les comptages de points d'intérêt par grille constituent un indicateur indirect de la structure urbaine locale et de la densité de services environnants. Pour chaque grille g , les comptages de différents types de points d'intérêt (arrêts de bus, établissements scolaires, administrations, mosquées, hôpitaux, pharmacies) sont agrégés en un vecteur $\mathbf{x}_g^{\text{poi}}$ de dimension fixe. Comme toutes les grilles n'ont pas de points d'intérêt associés, un alignement sur l'ensemble des grilles actives est effectué, les valeurs manquantes étant remplacées par zéro.

Les valeurs brutes sont transformées selon $\log(1 + \text{comptage})$ pour atténuer l'influence des valeurs extrêmes. Cette transformation logarithmique est particulièrement importante pour les types de points d'intérêt à forte présence urbaine (pharmacies, écoles, mosquées) dont les comptes peuvent atteindre des valeurs élevées dans les centres-ville. La transformation $\log(1 + x)$ préserve la propriété $\log(1 + 0) = 0$, garantissant qu'une grille dépourvue de tout point d'intérêt d'un type donné a une contribution nulle pour ce type.

Pression concurrentielle et environnement commercial

La surface de vente fait l'objet d'un traitement sophistiqué. On calcule d'abord le logarithme de la surface de chaque magasin, $\log(\sigma_s)$, puis on estime la moyenne μ_f et l'écart-type σ_f de cette grandeur pour chaque format f . La surface normalisée intra-format est définie comme :

$$\tilde{\sigma}_s = \frac{\log(\max(\sigma_s, \varepsilon)) - \mu_{f(s)}}{\sigma_{f(s)}}, \quad (3.2)$$

où $\varepsilon = 10^{-6}$ est un plancher numérique et $f(s)$ désigne le format du magasin s . Pour les magasins dont la surface est manquante, on impute $\tilde{\sigma}_s = 0$, ce qui correspond à la moyenne du format en échelle normalisée.

Cette double transformation, logarithme puis normalisation Z-score, capture la non-linéarité de l'effet surface sur l'attractivité. Ajouter 100 m² à un hypermarché de 10 000 m² est imperceptible, alors que le même ajout à un discount de 400 m² modifie nettement l'attractivité. Le logarithme rend l'effet concave, la normalisation par format le rend comparable d'un format à l'autre, et la standardisation Z-score garantit la stabilité numérique de l'inférence.

On intègre un vecteur $\mathbf{z}_{c(s)}$ de caractéristiques socio-démographiques de la commune $c(s)$ d'implantation du magasin s . Ces variables, normalisées selon la transformation Z-score variable par variable :

$$\tilde{z}_{c,d} = \frac{z_{c,d} - \bar{z}_d}{\text{std}(z_d)}, \quad (3.3)$$

où d indexe la variable démographique. Ces variables servent de contrôles dans le modèle de choix, capturant les hétérogénéités socio-économiques locales qui influencent les préférences de consommation.

3.5 Conception et gouvernance de la couche analytique

3.5.1 Modèle de données analytique

L'ensemble des sources est organisé sous forme de fichiers analytiques normalisés, sérialisés principalement en Apache Parquet. Le modèle retenu est un schéma en flocon de neige : une table centrale de paires grille-magasin porte les mesures d'accessibilité, tandis que les dimensions décrivent séparément les grilles, les magasins, les communes, les formats commerciaux et les points d'intérêt. Cette normalisation limite la redondance, rend les clés explicites et prépare directement les tableaux consommés par le pipeline de modélisation.

Table de faits paires_grille_magasin. Une ligne par paire active (`centroid_idx`, `Shop code`), soit environ 2,5 millions de lignes après filtrage métier final. La clé est composée de `centroid_idx` et `Shop code`. Les attributs principaux sont `distance_m_walk`, `duration_s_drive` et `pair_format_idx`, ce dernier étant précalculé afin d'éviter des jointures répétées lors de l'estimation.

Dimension dim_grilles. Une ligne par centroïde actif. Les attributs conservés sont `centroid_idx`, la population DN, l'indice de richesse `Indice_richesse_IRIS` et `code_commune`, qui relie chaque grille à sa commune.

Dimension dim_magasins. Une ligne par point de vente. Les attributs décrivent la marque `Brand`, le concept commercial `Shop concept`, le format `Cluster`, la surface, le chiffre d'affaires `CA N`, le rayon alcool, les indicateurs `ours`, `ours_CA` et `to_consider`, ainsi que l'ancienneté transformée `months_passed_f`.

Dimension dim_communes. Une ligne par commune, identifiée par `code`. Elle contient le nom de la commune et les variables socio-démographiques normalisées issues du HCP : structure d'âge, éducation, alphabétisation en français, statut matrimonial, emploi privé, taille moyenne du ménage et taux de propriétaires.

Dimension dim_formats. Une ligne par format commercial `Cluster`. Cette table est dérivée de `dim_magasins` et contient les statistiques agrégées utilisées pour la normalisation intra-format : `surface_mean`, `surface_std` et `n_stores`.

Table pois_data. Une ligne par couple (`centroid_idx`, `POI_type`). Elle rattache à chaque grille le nombre de points d'intérêt observés par type, via l'attribut `count`.

Conceptuellement, l'architecture articule deux entités principales reliées par la table de paires : la grille g , unité de demande de $100\text{ m} \times 100\text{ m}$, et le magasin s , unité d'offre. La commune enrichit la grille par des variables socio-démographiques, les points d'intérêt décrivent son environnement local, et le format $f(s)$ typifie le magasin pour les normalisations et les effets différenciés par segment.




Figure 3.7 : Schéma analytique en flocon de neige

Le format Apache Parquet[25] est retenu pour le stockage intermédiaire et la sérialisation des données vers le pipeline de modélisation. Parquet est un format orienté colonnes, compressé (Snappy[26] ou Zstd[27]), qui offre des performances de lecture sélective supérieures aux formats orientés lignes (CSV, JSON) pour les workloads analytiques. La lecture sélective de colonnes, par exemple charger uniquement DN et `code_commune` depuis `grids_data` sans décompresser `Indice_richesse_IRIS`, réduit drastiquement l’empreinte mémoire. Cette propriété est particulièrement cruciale pour la table de distance `distance_grid_store.parquet` : charger les cinq colonnes complètes de 2,5 millions de lignes nécessite environ 62 Mo en format Parquet, contre plus de 200 Mo en format CSV non compressé.

L’organisation en row groups de Parquet permet également de filtrer les données au niveau du stockage : si une requête ne concerne que les grilles d’une commune donnée, Parquet peut sauter les row groups qui ne contiennent pas ces grilles, réduisant le temps de lecture d’un ordre de grandeur. Cette propriété est exploitée par le pipeline de modélisation, qui charge les données par lot selon les communes.

3.5.2 Traçabilité, documentation et reproductibilité

Le stockage et la sauvegarde reposent sur plusieurs couches. Les fichiers Parquet intermédiaires sont synchronisés avec contrôle de version. Les scripts sont versionnés sous GitHub. Ces couches garantissent que chaque étape du pipeline, des données brutes aux données sérialisées, est recoverable en cas de panne ou d’erreur d’ingestion.

La traçabilité est assurée par l’horodatage de chaque fichier Parquet. Le pipeline d’ingestion constitue le contrat d’interface entre la couche données et la couche modélisation : toute modification de schéma amont est immédiatement visible. Les logs d’ingestion, nombre de lignes, plages de valeurs, nombre de valeurs manquantes, sont conservés.

Les chiffres d’affaires par magasin (`ours_CA`) constituent des données commerciales confidentielles

de Label’Vie. Leur accès et leur utilisation sont encadrés par des mécanismes de contrôle d’habilitation et des règles de gouvernance des données internes. Dans le cadre de ce projet, ces données ont été exploitées dans un environnement de traitement sécurisé et strictement interne, conformément aux permissions accordées.

Assemblage du DataBundle L’ensemble des grandeurs produites, vecteurs d’index, variables continues, indicateurs, métadonnées, est finalement assemblé dans une structure unique, le Data-Bundle, prête à être chargée par le modèle bayésien. Les champs principaux sont les suivants : `gidx` et `sidx` (index des paires), `N_pairs` (cardinalité de l’espace de choix), `log_walk` et `log_drive` (distances logarithmiques), `population` (population par grille), `log_surface_norm` (surface normalisée intra-format), `wealth_norm` (indice de richesse normalisé), `ancien_our_mois` (ancienneté en mois), `log_pois` (points d’intérêt transformés), `alcohol_our` (indicateur de rayon alcool), `demo_norm` (variables démographiques communales normalisées), `observed_revenue` (revenu observé étendu), et `total_other` (masse concurrentielle agrégée).

Cette structure constitue le contrat d’interface entre la couche données et la couche modélisation : toute modification de schéma amont est immédiatement visible, et chaque champ est typé et dimensionné pour être consommé directement par les opérations tensorielles du modèle.

Conclusion du chapitre

Nous avons documenté l’ensemble de la chaîne de valeur de la donnée, depuis l’acquisition multi-source jusqu’à la mise à disposition d’une couche analytique en flocon de neige. Cinq familles de sources, grille de population GHS-POP calibrée HCP, données internes Label’Vie, données concurrentielles, données de mobilité OSRM et données socio-économiques, convergent d’abord vers une matrice brute de 7,9 millions de paires grille-magasin. Après application des seuils métier par format, cette matrice est réduite à environ 2,5 millions de paires constituant l’espace de choix effectif du modèle.

Le choix d’EPSG :32629 comme projection métrique commune constitue l’épine dorsale géospatiale du système. Il garantit la cohérence des calculs euclidiens utilisés en pré-filtrage, avant que les distances et durées réellement utilisées par le modèle soient recalculées sur le réseau via OSRM.

La qualité de chaque étape conditionne directement la validité des estimations du modèle bayésien : filtrage SAM des grilles fantômes, pré-filtrage euclidien, routage OSRM, filtrage métier par format, normalisation des variables continues, imputation des valeurs manquantes et transformation logarithmique des grandeurs d’accessibilité exprimées en kilomètres et en minutes. L’implémentation détaillée du pipeline de prétraitement et d’ingénierie des variables est consultable dans le dépôt GitHub du projet en annexe. Le chapitre suivant expose la spécification et l’estimation du modèle de choix discret spatial qui consomme cette architecture de données.

Spécification du modèle structurel bayésien de la demande potentielle

Introduction

Ce chapitre pose la spécification complète du modèle structurel bayésien estimant la demande potentielle en grande distribution alimentaire au Maroc. L’objet est double : d’une part, quantifier l’attractivité perçue d’un magasin par la population d’une zone géographique élémentaire, ce que nous appelons le *côté offre* ou *côté utilité*, d’autre part, estimer la capacité de dépense alimentaire de cette même zone, le *côté marché*. La séparation explicite de ces deux composantes est un choix de modélisation délibéré. Elle garantit une identification claire des effets : l’utilité V_{gs} capture les déterminants de la préférence effectivement activés dans l’implémentation courante (distance, surface, interaction surface–population et variables démographiques), tandis que la capacité de dépense M_g encode les déterminants du pouvoir d’achat (population, richesse locale, tissu urbain). Les deux composantes sont couplées par la vraisemblance, mais leurs paramètres ne se confondent pas.

Les hyperparamètres numériques présentés dans ce chapitre, centres μ et écarts-types σ des distributions a priori, proviennent d’un calibrage métier combinant expertise interne, ordres de grandeur opérationnels et contraintes d’identification statistique. Ils ne constituent pas une version définitive du modèle : ils servent à illustrer une spécification bayésienne cohérente, révisable au fil des diagnostics posteriori, des comparaisons de variantes et des retours des équipes métier.

Le cadre général est celui du modèle de choix discret. Rappelons brièvement que l’utilité perçue par la population de la grille g pour le magasin s se décompose en une composante déterministe V_{gs} et un résidu aléatoire ε_{gs} , et que la probabilité de choix résulte de cette utilité totale selon une structure multinomiale ou nichée. Le présent chapitre spécifie la forme fonctionnelle de V_{gs} , la construction de M_g , la vraisemblance reliant revenus prédits et revenus observés.

4.1 Architecture générale du modèle

Le modèle articule deux composantes orthogonales. Le *côté attractivité* définit la répartition relative de la préférence, *comment* les consommateurs d’une grille g répartissent leur attention entre les magasins

accessibles, mesuré par l'utilité déterministe V_{gs} . Le *côté marché* définit le volume absolu, *combien* ces consommateurs disposent à dépenser, mesuré par la capacité de dépense M_g . Les deux composantes sont indépendantes dans la spécification a priori, mais couplées dans la vraisemblance : un magasin très attractif dans une zone pauvre génère moins de revenu qu'un magasin moyennement attractif dans une zone aisée.

Soit $\mathcal{G}$ l'ensemble des G grilles géographiques élémentaires (mailles GHS), $\mathcal{S}$ l'ensemble des S magasins modernes répertoriés, et $\mathcal{F} = \{\text{Discounter, Proxi, Market, Hyper, HyperCash}\}$ l'ensemble des formats. Chaque magasin s appartient à un format $f(s) \in \mathcal{F}$. Pour chaque grille g , l'ensemble des magasins accessibles est noté $\mathcal{S}(g) \subseteq \mathcal{S}$. L'ensemble des paires (g, s) retenues après application des seuils de distance constitue l'espace d'inférence, de cardinal N_{pairs} . Les magasins de l'enseigne LabelVie forment le sous-ensemble $\mathcal{S}^{\text{LV}} \subset \mathcal{S}$, de cardinal K , les magasins concurrents sont $\mathcal{S} \setminus \mathcal{S}^{\text{LV}}$.

La capacité totale de dépense de la grille g , notée M_g , est construite comme le produit de trois facteurs : la population effective, le panier moyen journalier et un multiplicateur captant l'intensité du tissu urbain local. La dépense de la grille g vers le magasin s , la fraction de M_g allouée à s selon la probabilité de choix, est $\text{spend}_{gs} = P_{gs} \cdot M_g$. Le revenu annuel prédit pour le magasin s s'obtient en agrégeant sur toutes les grilles dont s fait partie de l'espace de choix.

La première étape de la modélisation consiste à définir, pour chaque grille g , l'ensemble des alternatives raisonnablement accessibles, l'*espace de choix* $\mathcal{S}(g)$. Cette définition n'est pas arbitraire : elle repose sur l'observation que le comportement d'achat en grande distribution alimentaire est structuré par le format du magasin, chaque format imposant une géographie de chalandise propre.

L'option extérieure. L'espace de choix $\mathcal{S}(g)$ ne couvre pas l'univers entier des alternatives d'achat de la grille g . Une part significative, majoritaire dans de nombreuses zones, de la dépense alimentaire marocaine s'effectue en dehors de la grande distribution moderne répertoriée. Pour capturer cette réalité, on introduit formellement une *option extérieure* s_0 , normalisée à utilité nulle :

$$V_{g,s_0} = 0. \quad (4.1)$$

Cette convention d'identification est standard dans la littérature du choix discret : l'option extérieure sert de référence, et les utilités des alternatives observées sont mesurées relativement à elle. Une utilité positive $V_{gs} > 0$ signifie que le magasin s est perçu comme strictement préférable à l'ensemble des alternatives non modélisées, une utilité négative signifie le contraire. La moyenne des constantes alternatives est centrée à zéro ($\sum_f \alpha_f = 0$), ce qui implique qu'un format dont la constante est positive attire au-delà de la masse de l'option extérieure, tandis qu'un format à constante négative en capte moins, la part résiduelle étant absorbée par s_0 .

L'option extérieure regroupe trois catégories d'alternatives : le commerce traditionnel de proximité (souks, épiceries de quartier, vendeurs ambulants), les magasins modernes non répertoriés dans les données de scraping disponibles, et les achats effectués en dehors de la zone géographique couverte par les grilles. Dans le contexte marocain, cette distinction est économiquement fondamentale. Le commerce de proximité traditionnel représente encore une part prépondérante de la distribution alimentaire, en particulier dans les zones périurbaines et rurales. Ne pas inclure l'option extérieure reviendrait à imposer la contrainte $\sum_{s \in \mathcal{S}(g)} P_{gs} = 1$, c'est-à-dire à supposer que chaque dirham dépensé en alimentaire l'est nécessairement dans un magasin moderne, hypothèse manifestement fausse qui surestimerait mécaniquement l'attractivité de toutes les enseignes observées.

Avec l'option extérieure, la contrainte de normalisation est :

$$\sum_{s \in \mathcal{S}(g) \cup \{s_0\}} P_{gs} = 1, \quad (4.2)$$

où P_{gs} désigne la probabilité que la grille g choisisse le magasin s (ou l'option extérieure si $s = s_0$). Chaque dirham dépensé l'est nécessairement quelque part : dans un magasin du modèle, ou dans l'univers non capturé par s_0 . Cette contrainte ancre le modèle dans la réalité du marché total et garantit que les probabilités de choix estimées sont cohérentes avec la répartition macro des dépenses alimentaires.

4.2 Spécification de la composante d'utilité V_{gs}

Interprétation économique de l'utilité magasin-zone

Conformément au cadre du modèle de choix discret, l'utilité perçue par la population de la grille g pour le magasin s de format $f(s)$ se décompose en une composante déterministe observable V_{gs} et un terme d'erreur aléatoire ε_{gs} :

$$U_{gs} = V_{gs} + \varepsilon_{gs}, \quad \varepsilon_{gs} \sim \text{Gumbel}(0, 1) \text{ i.i.d.} \quad (4.3)$$

La composante déterministe, celle que le modèle spécifie et estime, est additive et indexée sur la paire (g, s) . Chaque terme est défini conjointement avec sa distribution a priori afin de lier directement l'interprétation économique et la paramétrisation bayésienne.

Forme fonctionnelle de l'attractivité magasin

La forme fonctionnelle de V_{gs} est :

$$\begin{aligned} V_{gs} = & \alpha_{f(s)} - \beta_{f(s)}^{\text{walk}} \cdot \log d_{gs}^{\text{walk}} - \beta_{f(s)}^{\text{drive}} \cdot \log d_{gs}^{\text{drive}} \\ & + \beta_{f(s)}^{\text{surf}} \cdot \tilde{\sigma}_s + \beta^{\text{sp}} \cdot \tilde{\sigma}_s \cdot \tilde{n}_s + \mathbf{b}_{\text{demo}}^\top \mathbf{z}_{c(s)} + \gamma_{q(s)} \end{aligned} \quad (4.4)$$

Dans cette expression, $\tilde{\sigma}_s$ désigne la surface de vente normalisée du magasin s au sein de son format, $\tilde{n}_s$ est la population locale normalisée autour du magasin, $\mathbf{z}_{c(s)}$ est le vecteur de variables démographiques communales associé à la commune $c(s)$, et $\gamma_{q(s)}$ désigne l'effet du concept commercial $q(s)$. La spécification de V_{gs} présentée ici correspond à la version codée du modèle : chaque variable d'attractivité est définie ci-dessous avec le prior effectivement utilisé.

Définition et paramétrisation des variables d'utilité

Constante alternative par format, $\alpha_{f(s)}$. Ce terme capture l'attractivité intrinsèque du format, indépendante des caractéristiques géographiques ou locales. Il est estimé à partir d'un effet brut centré ensuite pour l'identifiabilité, l'option extérieure ayant une utilité normalisée à zéro :

$$\alpha_f^{\text{raw}} \sim \mathcal{N}(\mu_f^\alpha, 1.5^2), \quad \alpha_f = \alpha_f^{\text{raw}} - \frac{1}{|\mathcal{F}|} \sum_{f' \in \mathcal{F}} \alpha_{f'}^{\text{raw}}. \quad (4.5)$$

Les centres utilisés dans le script sont $\mu_{\text{Discounter}}^\alpha = -1.0$, $\mu_{\text{Proxi}}^\alpha = -0.3$, $\mu_{\text{Market}}^\alpha = 0.8$, $\mu_{\text{Hyper}}^\alpha = 1.5$ et $\mu_{\text{HyperCash}}^\alpha = 1.5$. L'écart-type commun de 1.5 encode l'ordre de grandeur attendu sans figer le classement entre formats.

Frictions de distance, $\beta_{f(s)}^{\text{walk}}$ et $\beta_{f(s)}^{\text{drive}}$. Ces coefficients mesurent la pénalité d'accessibilité : plus le temps de marche ou de conduite augmente, plus l'utilité diminue. Le signe négatif est porté directement par l'équation de V_{gs} , tandis que les coefficients sont contraints positifs par des HalfNormal :

$$\beta_f^{\text{walk}} \sim \text{HalfNormal}(0, \sigma_f^{\text{walk}}), \quad \beta_f^{\text{drive}} \sim \text{HalfNormal}(0, \sigma_f^{\text{drive}}). \quad (4.6)$$

Les écarts-types par format sont ceux du dictionnaire de priors du code :

Format	σ_f^{walk}	σ_f^{drive}
Discounter	1.5	0.2
Proxi	1.0	0.3
Market	0.5	0.5
Hyper	0.5	0.2
HyperCash	0.1	0.2

Cette paramétrisation laisse une pénalité piétonne plus flexible pour les formats de proximité et régularise davantage les formats pour lesquels la marche est moins déterminante.

Élasticité-surface, $\beta_{f(s)}^{\text{surf}} \tilde{\sigma}_s$. La surface normalisée représente la capacité d'offre du magasin : assortiment plus large, expérience d'achat plus complète et capacité à absorber davantage de demande. Le coefficient est positif par construction :

$$\beta_f^{\text{surf}} \sim \text{HalfNormal}(0, \sigma_f^{\text{surf}}), \quad \beta_f^{\text{surf}} > 0. \quad (4.7)$$

Les écarts-types utilisés sont $\sigma_{\text{Discounter}}^{\text{surf}} = 0.20$, $\sigma_{\text{Proxi}}^{\text{surf}} = 0.15$, $\sigma_{\text{Market}}^{\text{surf}} = 0.10$, $\sigma_{\text{Hyper}}^{\text{surf}} = 0.05$ et $\sigma_{\text{HyperCash}}^{\text{surf}} = 0.05$. Ces valeurs remplacent les anciens priors plus serrés et correspondent à l'implémentation active.

Interaction surface $\times$ population locale, $\beta^{\text{sp}} \tilde{\sigma}_s \tilde{n}_s$. Ce terme capte la synergie entre la taille du magasin et la masse de demande autour du point de vente : un grand magasin situé dans une zone dense peut produire une attractivité supérieure à la somme des deux effets isolés. Le prior utilisé est :

$$\beta^{\text{sp}} \sim \mathcal{N}(0.1, 0.15^2). \quad (4.8)$$

Il est centré légèrement au-dessus de zéro, tout en laissant au modèle la possibilité d'apprendre un effet faible ou incertain.

Effets démographiques, $\mathbf{b}_{\text{demo}}^\top \mathbf{z}_{c(s)}$. Les variables démographiques communales contrôlent des différences locales non captées par la distance ou la surface : niveau d'éducation, structure des ménages, statut résidentiel ou emploi. Leur effet est régularisé par un prior symétrique, car le signe attendu n'est pas imposé :

$$b_{\text{demo},j} \sim \mathcal{N}(0, 0.3^2), \quad j = 1, \dots, p_{\text{demo}}. \quad (4.9)$$

Effet de concept commercial, $\gamma_{q(s)}$. Le script ajoute un effet de concept au niveau de l'utilité afin de capter des différences d'attractivité liées au positionnement commercial du magasin, au-delà du format. Cet effet est hiérarchiquement régularisé :

$$\sigma_{\text{concept}} \sim \text{HalfNormal}(0, 0.3), \quad \gamma_q = \sigma_{\text{concept}} \gamma_q^{\text{raw}}, \quad \gamma_q^{\text{raw}} \sim \mathcal{N}(0, 1). \quad (4.10)$$

Ce shrinkage évite de surinterpréter les concepts rares tout en permettant au modèle d'apprendre un décalage d'attractivité lorsque les données le justifient.

Probabilités de choix et allocation de la demande

Sous l'hypothèse d'erreurs i.i.d. Gumbel, la probabilité que la grille g choisisse le magasin $s \in \mathcal{S}(g)$ s'écrit en développant explicitement le dénominateur avec l'option extérieure :

$$P_{gs} = \frac{\exp(V_{gs})}{\exp(V_{gs}) + \sum_{\substack{s' \in \mathcal{S}(g) \\ s' \neq s}} \exp(V_{gs'}) + \exp(0)} = \frac{\exp(V_{gs})}{\sum_{s' \in \mathcal{S}(g)} \exp(V_{gs'}) + 1}. \quad (4.11)$$

Le terme $+1$ au dénominateur est l'apport de l'option extérieure s_0 dont $V_{g,s_0} = 0$. La somme $\sum_{s \in \mathcal{S}(g) \cup \{s_0\}} P_{gs} = 1$ est satisfaite par construction. Cette forme logistique multinomiale est la vraisemblance de choix la plus directement justifiée par la structure générative du modèle.

La version nichée, Nested Logit par format. Le modèle MNL standard postule l'indépendance des alternatives non observées (INU) : le ratio des probabilités de choix entre deux alternatives ne dépend pas de la présence ou des caractéristiques des autres alternatives. Cette hypothèse est violée dans notre contexte : les magasins d'un même format sont davantage substituables entre eux qu'avec des magasins d'un autre format. Un consommateur arbitrant entre un discounter et un autre discounter effectue une comparaison qualitativement différente de l'arbitrage entre un discounter et un hypermarché. Les magasins d'un même format partagent des similarités structurelles, surface comparable, agencement similaire, assortiment homogène, positionnement tarifaire proche, qui les rendent plus interchangeables.

Le Nested Logit corrige cette violation en organisant les alternatives en nids disjoints. Dans notre spécification, les nids sont les formats. Le paramètre de dissimilarité $\lambda_f \in (0, 1)$, spécifique à chaque format f , mesure le degré de substitution intra-nid : $\lambda_f \rightarrow 1$ retrouve le MNL standard (substitution indépendante), $\lambda_f \rightarrow 0$ implique une substitution quasi-parfaite au sein du format.

Distribution a priori de λ_f .

$$\lambda_f \sim \text{Beta}(\alpha_\lambda, \beta_\lambda), \quad f \in \mathcal{F}. \quad (4.12)$$

Si l'on croit a priori à une forte corrélation intra-nid (substitution élevée au sein du format), la Beta informative $\mathcal{B}(6, 2)$ centre la masse sur $\mathbb{E}[\lambda_f] = 0.75$ avec une variance réduite. Si l'on est agnostique, $\mathcal{B}(2, 2)$ est symétrique sur $(0, 1)$ avec une moyenne de 0.5, spécification par défaut non informative.

Statistique inclusive. Pour chaque grille g et format f , la statistique inclusive (log-sum) est :

$$I_g^f = \log \left(\sum_{s \in \mathcal{S}(g), f(s)=f} \exp(V_{gs}) \right). \quad (4.13)$$

Elle résume l'attractivité agrégée de tous les magasins du format f accessibles depuis g .

Utilité étendue du nid. L'utilité perçue du nid f par la grille g incorpore la statistique inclusive pondérée par le paramètre de dissimilarité :

$$\tilde{V}_g^f = \alpha_f + \lambda_f \cdot I_g^f. \quad (4.14)$$

Probabilité cross-format. La probabilité que la grille g choisisse le format f (contre tout autre format ou l'option extérieure) est :

$$P(f | g) = \frac{\exp(\tilde{V}_g^f)}{\sum_{f' \in \mathcal{F}} \exp(\tilde{V}_g^{f'}) + 1}. \quad (4.15)$$

Probabilité conditionnelle within-nest. Conditionnellement au choix du format f , la probabilité de sélectionner le magasin s parmi les magasins de ce format est :

$$P(s | f, g) = \frac{\exp(V_{gs})}{\sum_{\substack{s' \in \mathcal{S}(g) \\ f(s')=f}} \exp(V_{gs'})}. \quad (4.16)$$

Probabilité marginale complète. La probabilité jointe est le produit des deux étapes :

$$P_{gs} = P(s | f(s), g) \cdot P(f(s) | g). \quad (4.17)$$

Dans l'implémentation courante, λ_f agit au niveau cross-format en modulant le poids de la statistique inclusive I_g^f dans l'utilité du nid, tandis que la répartition within-format reste un softmax standard sur les utilités magasin. Le paramètre suit $\lambda_f \sim \text{Beta}(2, 2)$ dans la version standard, ou $\lambda_f \sim \text{Beta}(6, 2)$ dans la variante informative.

4.3 Spécification de la composante de marché M_g

Le côté attractivité définit la répartition relative de la préférence, *comment* les consommateurs d'une grille g répartissent leur attention entre les magasins accessibles. Le côté marché définit le volume absolu, *combien* ces consommateurs disposent à dépenser. Les deux composantes sont indépendantes dans la spécification a priori, mais couplées dans la vraisemblance : un magasin très attractif dans une zone pauvre génère moins de revenu qu'un magasin moyennement attractif dans une zone aisée.

La capacité totale de dépense de la grille g , notée M_g , est construite comme le produit de trois facteurs : la population effective, le panier moyen de base spécifique au format (basé sur les dépenses moyennes par visite) et un multiplicateur captant l'intensité du tissu urbain local.

$$M_{g,f} = 360 \cdot N_g^{\beta_{\text{pop}}} \cdot \mu_{f,g} \cdot \exp\left(\mathbf{b}_{\text{poi}}^\top \log(1 + \mathbf{x}_g^{\text{poi}})\right). \quad (4.18)$$

où 360 correspond au nombre de jours d'ouverture annuel des magasins.

Dépense de base par format. Le panier de base d'un magasin de format f suit une loi log-normale centrée sur une médiane calibrée PM_f (issue des données internes : ≈ 20 MAD pour *Discounter*, 60 MAD pour *Proxi*, 90 MAD pour *Market*, 100 MAD pour *Hyper*). On pose

$$\mu_{0,f} \sim \text{LogNormal}(\log(\text{PM}_f), \sigma_f^2), \quad (4.19)$$

où σ_f est un écart-type propre à chaque format. Il est calibré sur l'étendue log-panier vraisemblable selon $\sigma_f = \frac{1}{4} [\log(\text{PM}_f^{\text{max}}) - \log(\text{PM}_f^{\text{min}})]$, ce qui donne des valeurs comprises entre 0.19 et 0.43 selon le format.

Effet richesse borné par sigmoïde. L'impact du pouvoir d'achat local w_g sur la dépense est modélisé par une transformation sigmoïdale :

$$\phi(w_g) = \frac{1 + \tanh(\xi \cdot w_g)}{2}. \quad (4.20)$$

Le paramètre $\xi \sim \text{HalfNormal}(0, 0.5)$ contrôle la pente de la saturation. La fonction $\tanh$ encode une saturation naturelle de la dépense alimentaire. La transformation $\phi(w_g)$ est bornée sur $(0, 1)$ et monotone croissante en w_g , garantissant une cohérence économique : une grille plus riche dispose d'une capacité de dépense plus élevée, *ceteris paribus*.

Uplift maximal. L'amplitude maximale de l'augmentation de la capacité de dépense au-dessus du baseline est un paramètre borné sur $(0, 1)$:

$$\delta_{\text{max}} \sim \text{Beta}(2, 2). \quad (4.21)$$

La Beta symétrique $(2, 2)$ est centrée sur 0.5 avec une variance modérée. Elle exprime l'incertitude sur l'intensité de l'effet richesse tout en excluant les extrêmes a priori.

Formule complète de la capacité de dépense locale. La structure de base devient alors une capacité de dépense normalisée qui dépend du format du magasin :

$$\mu_{f,g} = \mu_{0,f} \cdot (1 + \delta_{\text{max}} \cdot \phi(w_g)). \quad (4.22)$$

Cette quantité $\mu_{f,g}$ représente la capacité de dépense alimentaire de la paire magasin-grille, indépendante des autres effets (points d'intérêt, etc.). Elle constitue le niveau structurel de demande locale utilisé dans la suite du modèle.

Calibration de la population. La population N_g de la grille g , issue des données GHS, est une estimation comportant une incertitude structurelle : interpolation infracommune à partir des données de recensement, décalage temporel entre le recensement de référence et la période d'observation, et imprécision inhérente à la modélisation satellite de la population résidente. Pour corriger cette incertitude, le paramètre β_{pop} apprend à recalculer la population estimée sur le signal réel des revenus

observés :

$$\beta_{\text{pop}} \sim \mathcal{N}(1.0, 0.4^2), \text{ tronqué sur } [0, 2]. \quad (4.23)$$

La population effective utilisée dans la capacité de marché est $N_g^{\beta_{\text{pop}}}$. Lorsque $\beta_{\text{pop}} = 1$, la relation est linéaire, chaque habitant supplémentaire contribue proportionnellement. Lorsque $\beta_{\text{pop}} < 1$, la contribution marginale de la population décroît (rendements décroissants de la densité), lorsque $\beta_{\text{pop}} > 1$, elle croît (rendements croissants, effets de réseau). La troncature sur $[0, 2]$ exclut les régimes non physiques.

Effet des points d'intérêt urbains. Les points d'intérêt (POI), arrêts de bus, établissements scolaires, institutions administratives, mosquées, hôpitaux, sont des proxies du trafic piéton et de l'intensité du tissu urbain commercial. Leur effet est modélisé comme un facteur multiplicatif exponentiel :

$$\Psi_g = \exp\left(\mathbf{b}_{\text{poi}}^\top \log(1 + \mathbf{x}_g^{\text{poi}})\right), \quad (4.24)$$

où $\mathbf{x}_g^{\text{poi}}$ est le vecteur de comptages de POI par type dans la grille g . La transformation $\log(1 + \cdot)$ assure une dégressivité : le passage de zéro à un POI a un effet plus fort que le passage de cent à cent-un. La forme exponentielle $\exp(\cdot)$ garantit que le facteur est au pire neutre, dans les zones sans POI, $\log(1 + 0) = 0$ et $\Psi_g = \exp(0) = 1$, jamais négatif. L'effet POI est secondaire par rapport au panier moyen et à la population, mais il capture des variations locales de densité commerciale que ces deux variables seules ne rendent pas compte.

Une remarque sur les données manquantes : dans certaines zones, l'absence de POI répertoriés ne signifie pas nécessairement l'absence de tissu urbain, elle peut refléter un manque d'intérêt pour le labellisation des données ouvertes dans ces régions. Cette absence est elle-même informative : elle constitue un proxy d'un état d'esprit moins tourné vers la modernisation ou vers les services formels, ce qui est cohérent avec une moindre intensité commerciale de tout type.

4.4 Couplage probabiliste entre offre et marché

Probabilités de choix et allocation de la demande

La dépense de la grille g vers le magasin s , la fraction de M_g allouée à s selon la probabilité de choix, est :

$$\text{spend}_{gs} = P_{gs} \cdot M_g. \quad (4.25)$$



Figure 4.1 : Allocation de la demande depuis le centroïde de la grille (étoile jaune) vers les magasins environnants (triangles) en fonction des probabilités de choix estimées.

Le revenu annuel prédit pour le magasin s s'obtient en agrégeant sur toutes les grilles dont s fait partie de l'espace de choix :

$$\hat{R}_s = \sum_{g: s \in \mathcal{S}(g)} \text{spend}_{gs} = \sum_{g \in \mathcal{G}(s)} P_{gs} \cdot M_g, \quad (4.26)$$

où $\mathcal{G}(s) = \{g \in \mathcal{G} : s \in \mathcal{S}(g)\}$ est l'ensemble des grilles pour lesquelles s est accessible.

Pour les magasins LabelVie, notés $\mathcal{S}^{\text{LV}}$, le vecteur des revenus prédits est $\hat{\mathbf{R}}^{\text{LV}} = (\hat{R}_s)_{s \in \mathcal{S}^{\text{LV}}}$. Le terme agrégé des revenus non-LabelVie, nécessaire à la construction de la vraisemblance, détaillée à la section suivante, est :

$$\hat{R}_{\text{autres}} = \sum_{s \in \mathcal{S}} \hat{R}_s - \sum_{s \in \mathcal{S}^{\text{LV}}} \hat{R}_s. \quad (4.27)$$

Revenus prédits et agrégation au niveau magasin

Avant de comparer les revenus prédits aux revenus observés, deux effets de structure sont neutralisés par des scalings appris. Ces scalings ne modifient pas les probabilités de choix, ils opèrent *après* le calcul du revenu prédit, sur le vecteur $\hat{\mathbf{R}}^{\text{LV}}$.

Ancienneté du magasin. Les données internes confirment que le chiffre d'affaires d'un magasin croît significativement durant ses premières années d'exploitation. Trois mécanismes se renforcent : la notoriété de l'enseigne dans la zone, la fidélisation progressive de la clientèle, et les ajustements opérationnels (réassortiment, horaires, mise en place). Pour pouvoir comparer des magasins d'âges différents, on applique un scaling par l'ancienneté normalisée. Soit a_s le nombre de mois d'exploitation du magasin s au moment de l'observation, seuls les magasins ayant complété au moins douze mois sont inclus dans la vraisemblance. Le scaling est :

$$\hat{R}_s^{\text{adj}} = \hat{R}_s \cdot \exp(b_{\text{old}} a_s), \quad b_{\text{old}} \sim \text{HalfNormal}(0, 0.08). \quad (4.28)$$

Le paramètre b_{old} apprend le taux de croissance log-linéaire mensuel du revenu en fonction de l'ancienneté. La forme exponentielle garantit un scaling strictement positif et interprète b_{old} comme une variation relative par mois. L'écart-type très serré de 0.08 reflète la précision relative attendue de cette relation dans les données internes.

Présence d'un rayon alcool. LabelVie est la seule enseigne de grande distribution au Maroc à intégrer un rayon alcool à grande échelle. Les données internes situent l'uplift de chiffre d'affaires associé entre 20% et 40% pour les magasins concernés. L'alcool affecte à la fois l'attractivité, captée par un terme dans l'utilité, et le panier moyen, captée par le scaling de post-traitement. Ce dernier effet est distinct : il ne s'agit pas seulement d'attirer plus de clients, mais d'augmenter le revenu total par client via un effet de panier. Le scaling exponentiel est :

$$\hat{R}_s^{\text{final}} = \hat{R}_s^{\text{adj}} \cdot \exp(b_{\text{alcool}} \cdot \mathbb{I}[\text{alcool}_s]), \quad b_{\text{alcool}} \sim \text{HalfNormal}(0, 0.5). \quad (4.29)$$

La forme exponentielle garantit un effet multiplicatif strictement positif. Avec $b_{\text{alcool}} \sim \text{HalfNormal}(0, 0.5)$, l'effet est volontairement fortement régularisé : le rayon alcool est traité comme un correctif de revenu post-allocation, non comme un moteur principal de la probabilité de choix.

Le revenu prédit final pour chaque magasin LabelVie est donc :

$$\hat{R}_s^{\text{final}} = \hat{R}_s \cdot \exp(b_{\text{old}} a_s) \cdot \exp(b_{\text{alcool}} \cdot \mathbb{I}[\text{alcool}_s]). \quad (4.30)$$

Spécification de la vraisemblance

La vraisemblance relie les revenus prédits du modèle aux revenus effectivement observés. Sa construction repose sur deux choix structurels : la composition du vecteur d'observation et la famille de distribution retenue pour modéliser les résidus de prédiction.

Soit $K = |\mathcal{S}^{\text{LV}}|$ le nombre de magasins LabelVie retenus dans l'analyse, ceux ayant complété au moins douze mois d'exploitation. Le vecteur observé $\mathbf{y}_{\text{obs}}$ est de dimension $K + 1$:

$$\mathbf{y}_{\text{obs}} = \left(R_1^{\text{obs}}, R_2^{\text{obs}}, \dots, R_K^{\text{obs}}, y_{\text{autres}} \right). \quad (4.31)$$

Les K premiers composés sont les revenus annuels observés de chaque magasin LabelVie, couvrant la période d'avril 2025 à avril 2026. Ces données proviennent des dossiers comptables internes et sont donc observées avec une précision élevée.

Le dernier terme, y_{autres} , est construit comme le résidu de la masse totale de dépenses alimentaires dans les communes couvertes, déduction faite des revenus LabelVie observés :

$$y_{\text{autres}} = \text{DEP_TOT_AL} - \sum_{k=1}^K R_k^{\text{obs}}. \quad (4.32)$$

La grandeur DEP_TOT_AL est la dépense alimentaire totale annuelle des ménages résidant dans les communes où les grilles et magasins sont situés, issue des données du HCP croisées avec les données internes de couverture géographique. Elle inclut les dépenses alimentaires et non-alimentaires, car les hypermarchés et markets génèrent un chiffre d'affaires mixte.

Le vecteur prédit symétrique est :

$$\hat{\mathbf{y}} = \left(\hat{R}_1^{\text{final}}, \dots, \hat{R}_K^{\text{final}}, \hat{R}_{\text{autres}} \right), \quad (4.33)$$

$$\text{où } \hat{R}_{\text{autres}} = \sum_{s \in \mathcal{S}} \hat{R}_s - \sum_{k=1}^K \hat{R}_k^{\text{final}}.$$

L'inclusion du terme agrégé y_{autres} est économiquement fondamentale. Les revenus individuels des concurrents ne sont pas observés, mais la masse macro de dépenses l'est. En ancrant le modèle dans cette contrainte de marché total, les probabilités de choix estimées doivent être cohérentes non seulement avec les CA LabelVie mais aussi avec la répartition globale de la dépense alimentaire dans les villes couvertes. Sans ce terme, le modèle pourrait surestimer l'attractivité de LabelVie en ignorant la contrainte que chaque dirham dépensé dans un magasin LabelVie est un dirham retiré du reste du marché. Le terme agrégé agit comme un régularisateur macroéconomique : il force le modèle à expliquer non pas seulement *combien* LabelVie vend, mais *quelle part* du marché total LabelVie capte.

Conclusion

Ce chapitre a posé la spécification du modèle structurel bayésien estimant la demande potentielle en grande distribution alimentaire au Maroc. La construction repose sur deux composantes distinctes : le côté attractivité, mesuré par l'utilité déterministe V_{gs} , et le côté marché, mesuré par la capacité de dépense M_g . Cette séparation permet de distinguer ce qui relève de la préférence relative pour les magasins accessibles de ce qui relève du volume de dépense disponible dans chaque grille.

Le chapitre a également défini l'espace de choix, l'option extérieure, les variables d'attractivité et leur paramétrisation, puis la construction de la capacité de marché à partir de la population, du panier moyen, de la richesse locale et des points d'intérêt urbains. Le couplage entre ces deux blocs s'effectue par les probabilités de choix P_{gs} , qui allouent la capacité de dépense locale aux magasins accessibles et produisent des revenus prédits au niveau magasin.

Enfin, la vraisemblance est structurée autour d'un vecteur observé combinant les revenus individuels des magasins LabelVie et le terme agrégé y_{autres} . Ce dernier joue un rôle central : il empêche le modèle de raisonner uniquement sur la performance de LabelVie et l'oblige à rester cohérent avec la masse totale de dépenses du marché couvert. Le chapitre suivant pourra donc s'appuyer sur cette spécification pour étudier les résultats d'estimation, les diagnostics et la qualité prédictive du modèle.

Discussion et Analyse des Résultats

Introduction

Ce chapitre présente les résultats empiriques du modèle bayésien de demande potentielle dans une logique de *Bayesian Workflow* [28]. L'objectif n'est pas seulement de choisir la variante qui minimise une erreur moyenne, mais d'évaluer ce que le modèle reproduit correctement, ce qu'il ne reproduit pas, et quelles défaillances sont importantes pour la décision d'implantation. Dans ce cadre, un modèle ajusté n'est pas accepté ou rejeté sur un seul indicateur : il est soumis à plusieurs diagnostics complémentaires, chacun portant sur un aspect différent de l'ajustement.

La démarche suit trois niveaux d'évaluation. Le premier niveau vérifie la stabilité de l'inférence variationnelle à travers la trajectoire de l'ELBO. Le deuxième niveau correspond au *contrôle prédictif a posteriori* : les données observées sont comparées à des jeux de données répliqués simulés depuis la distribution prédictive a posteriori. Le troisième niveau relève d'une logique de *validation croisée* : une partie des magasins est laissée hors de l'estimation, le modèle est ajusté sur l'échantillon d'entraînement, puis sa performance est évaluée sur les magasins laissés de côté. Cette séparation apprentissage/test ne remplace pas une validation croisée complète, mais elle joue le même rôle méthodologique : tester la capacité du modèle à prédire des observations qui n'ont pas servi à ajuster les paramètres.

Trois spécifications sont comparées sur la même architecture structurelle : une vraisemblance Laplace sur les log-revenus, une vraisemblance Student-T sur les log-revenus et une variante Student-T avec structure de choix nichée par format. Cette comparaison constitue une étape de *séquençage des vraisemblances* : on ne modifie pas encore toute la structure du modèle, mais on teste comment différentes hypothèses de vraisemblance sur les résidus influencent l'ajustement, la calibration et les erreurs par format. Les résultats doivent donc être lus comme une première itération de diagnostic, destinée à orienter les révisions suivantes du modèle.

Les trois modèles évalués partagent les mêmes variables explicatives et les mêmes a priori structurels. Ce choix est volontaire : il permet d'attribuer les écarts de performance à la vraisemblance et à la structure de choix, sans mélanger cet effet avec une modification simultanée des covariables. Les variables d'utilité restent donc les mêmes : distance piétonne, distance en voiture, surface normalisée par format, interaction surface-population, variables démographiques communales et effets liés à la capacité de dépense locale. La comparaison porte uniquement sur la manière dont le modèle transforme les écarts entre revenus observés et revenus prédits en information a posteriori.

Vraisemblance Laplace La première variante robuste modélise l'erreur dans l'espace logarithmique par une loi de Laplace :

$$\log y_i^{\text{obs}} \mid \hat{y}_i, b \sim \text{Laplace}(\log \hat{y}_i, b), \quad b \sim \text{HalfNormal}(0, 0.5). \quad (5.1)$$

Cette spécification pénalise les résidus proportionnellement à leur valeur absolue. Elle est donc moins sensible aux magasins atypiques qu'une erreur quadratique gaussienne.

Vraisemblance Student-T avec erreur par format La deuxième variante laisse le modèle apprendre la lourdeur des queues tout en autorisant une dispersion résiduelle différente selon le format du magasin. La vraisemblance reste définie dans l'espace logarithmique, mais le paramètre d'échelle n'est plus unique : chaque format f possède son propre écart-type σ_f , auquel s'ajoute un paramètre séparé σ_{other} pour l'option extérieure :

$$\log y_i^{\text{obs}} \mid \hat{y}_i, \sigma_{f(i)}, \nu \sim \text{StudentT}(\nu, \log \hat{y}_i, \sigma_{f(i)}), \quad \sigma_f \sim \text{HalfNormal}(1.0), \quad \nu \sim \text{Exponential}(1/3). \quad (5.2)$$

Pour les observations associées à l'option extérieure, l'échelle utilisée est définie séparément par

$$\sigma_{\text{other}} \sim \text{HalfNormal}(1.0). \quad (5.3)$$

Ici, $f(i)$ désigne le format du magasin i et $\sigma_{f(i)}$ mesure l'erreur résiduelle typique autorisée pour ce format dans l'espace des log-revenus. Cette structure correspond à une hypothèse d'hétéroscédasticité par format : l'incertitude prédictive n'est pas supposée identique pour un hypermarché, un supermarché, un magasin de proximité ou un discounter. Cette distinction est importante car les niveaux de chiffre d'affaires ne sont pas comparables entre formats. Un écart de plusieurs dizaines de millions de dirhams peut rester relativement modéré pour un hypermarché générant plusieurs centaines de millions, alors que le même écart devient très significatif pour un discounter dont le chiffre d'affaires attendu est beaucoup plus faible. En laissant le modèle apprendre un σ_f propre à chaque format, on évite donc d'imposer une même tolérance d'erreur à des magasins qui n'ont ni la même échelle économique ni la même variabilité opérationnelle.

Le paramètre σ_{other} joue le même rôle pour l'option extérieure, c'est-à-dire pour la part de demande qui n'est captée par aucun magasin observé dans l'ensemble de choix. Elle représente une source d'incertitude distincte, car l'erreur associée à cette alternative ne provient pas d'un revenu magasin directement comparable, mais d'une masse de demande résiduelle ou non observée. Enfin, lorsque ν est faible, les observations extrêmes ont moins de levier sur la distribution a posteriori, lorsque ν augmente, la Student-T se rapproche d'une normale sur les log-revenus. Cette vraisemblance est donc adaptée à une première phase d'exploration, où certaines ouvertures, zones locales, formats spécifiques ou erreurs de données peuvent produire des revenus atypiques.

5.1 Convergence de l'inférence variationnelle

Pour chaque variante de vraisemblance, l'inférence a été conduite par ADVI sur 5 000 itérations, avec un estimateur Monte Carlo de 3 échantillons par itération. Ce choix représente un compromis entre coût de calcul et stabilité du gradient. Dans un modèle où les revenus prédits sont obtenus par agrégation

de probabilités de choix sur un grand nombre de couples grille–magasin, les gradients peuvent être bruités, augmenter le nombre de tirages Monte Carlo par itération permet de réduire cette variabilité, au prix d'un temps de calcul plus élevé.

La convergence est suivie par l'ELBO (*Evidence Lower Bound*), objectif optimisé par l'inférence variationnelle :

$$\mathcal{L}(q) = \mathbb{E}_{q(\theta)}[\log p(y, \theta)] - \mathbb{E}_{q(\theta)}[\log q(\theta)]. \quad (5.4)$$

Plus l'ELBO est élevée, meilleure est l'approximation variationnelle de la loi a posteriori, toutes choses égales par ailleurs. Ici, elle sert surtout à vérifier que l'optimisation se stabilise et à comparer grossièrement les variantes estimées sur la même architecture.




Figure 5.1 : Convergence de l'ELBO pour les trois variantes de vraisemblance. La courbe brute est complétée par une moyenne mobile qui révèle la tendance globale de l'optimisation.

La Figure 5.1 montre que les trois optimisations présentent une trajectoire comparable. L'ELBO augmente rapidement durant les premières centaines d'itérations, puis atteint un plateau autour de 1 000 itérations. Cette dynamique indique que les principaux paramètres d'échelle sont identifiés tôt dans l'optimisation, puis que les itérations restantes servent surtout à stabiliser l'approximation variationnelle. Les oscillations observées autour du plateau sont cohérentes avec l'utilisation d'un gradient stochastique, elles ne traduisent pas une divergence de l'inférence.

Table 5.1 : Valeurs finales de l'ELBO après 5 000 itérations ADVI.

Modèle	ELBO final
Laplace	−491,66
Student-T	−488,05
Student-T nichée	−495,31

Le Tableau 5.1 indique que la Student-T obtient la meilleure borne variationnelle finale. L'écart avec Laplace reste limité, mais il va dans le même sens que les métriques prédictives présentées plus loin. La variante nichée obtient au contraire une ELBO plus faible. Ce résultat suggère que l'ajout des paramètres de dissimilarité par format ne compense pas, à ce stade, le surcoût de complexité. Autrement dit, il est prématuré de complexifier la structure de choix tant que les biais de base par format ne sont pas mieux corrigés.

5.2 Performance prédictive hors-échantillon

5.2.1 Métriques globales et erreurs par format

La validation hors-échantillon utilise une séparation apprentissage/test fixe. Elle est moins exhaustive qu'une validation croisée complète, mais elle répond à la question opérationnelle principale : le modèle conserve-t-il une capacité de prédiction raisonnable sur des magasins qui n'ont pas servi à l'estimation ?

Avant de lire les résultats, les métriques utilisées sont les suivantes. La MAPE (*Mean Absolute Percentage Error*) mesure l'erreur relative moyenne en pourcentage :

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (5.5)$$

Elle est facile à interpréter pour le métier : une MAPE de 20% signifie que la prédiction s'écarte en moyenne d'environ 20% du revenu observé. Le biais relatif mesure, lui, le sens moyen de l'erreur :

$$\text{Biais} = 100 \times \frac{\sum_{i=1}^n (\hat{y}_i - y_i)}{\sum_{i=1}^n y_i}. \quad (5.6)$$

Un biais positif indique une surestimation, un biais négatif une sous-estimation. La couverture HDI à 94% mesure la proportion des magasins observés dont le revenu réel tombe dans l'intervalle crédible à 94% de la distribution prédictive. La valeur 94% est un niveau usuel dans l'écosystème bayésien, notamment avec ArviZ, et sert ici de seuil exigeant mais lisible : un modèle bien calibré devrait couvrir une large majorité des observations test. Enfin, σ_f décrit l'erreur résiduelle apprise pour chaque format dans l'espace des log-revenus, $\exp(\sigma_f)$ l'exprime comme facteur multiplicatif approximatif, et σ_{other} représente l'incertitude associée à l'option extérieure.

Le Tableau 5.2 résume ces résultats par format. La lecture doit rester prudente, car l'ensemble test ne contient que seize magasins et certains formats, comme DISCOUNTER et HYPERCASH, ne comptent que deux observations.

Table 5.2 : Performance hors-échantillon par format : MAPE, biais relatif, couverture HDI à 94% et échelles résiduelles des variantes Student-T.

Modèle	Format	n	MAPE (%)	Biais (%)	Couv. 94	σ_f	$\exp(\sigma_f)$	σ_{other}
Nested Student	DISCOUNTER	2	198,5	101,7	0	0,449	1,566	1,973
Nested Student	HYPER	4	18,2	-1,9	1	0,766	2,152	1,973
Nested Student	HYPERCASH	2	20,7	-20,1	0,5	0,382	1,465	1,973
Nested Student	MARKET	4	48,5	-38,8	0,75	0,603	1,828	1,973
Nested Student	PROXI	4	64,6	-24,0	0,5	0,618	1,856	1,973
Laplace	DISCOUNTER	2	255,0	154,0	0	—	—	—
Laplace	HYPER	4	29,9	-12,9	0,5	—	—	—
Laplace	HYPERCASH	2	16,6	3,0	0,5	—	—	—
Laplace	MARKET	4	54,9	-28,1	0,25	—	—	—
Laplace	PROXI	4	99,1	-37,6	0	—	—	—
Student	DISCOUNTER	2	239,9	141,4	0	0,388	1,473	2,050
Student	HYPER	4	32,2	10,9	0,75	0,651	1,917	2,050
Student	HYPERCASH	2	20,4	-19,8	0,5	0,309	1,362	2,050
Student	MARKET	4	44,0	-44,7	0,25	0,548	1,729	2,050
Student	PROXI	4	56,1	-26,1	0,5	0,550	1,733	2,050

La première lecture porte sur la précision relative. HYPER et HYPERCASH sont les formats les mieux prédits : la meilleure MAPE atteint 18,2% pour HYPER avec la Student-T nichée, et 16,6% pour HYPERCASH avec Laplace. Ces niveaux indiquent que les variables actuelles décrivent assez bien les grands formats, où la surface, l’accessibilité automobile et le bassin de population expliquent une part importante du potentiel.

MARKET et PROXI restent plus difficiles. Pour MARKET, la Student-T simple donne la meilleure MAPE (44,0%), devant la Student-T nichée (48,5%) et Laplace (54,9%). Pour PROXI, la Student-T améliore nettement Laplace, avec une MAPE de 56,1% contre 99,1%. Ces deux formats sont cependant encore sous-estimés, ce qui suggère que le modèle ne capte pas complètement les effets de proximité fine, de centralité locale ou de fréquentation de quartier.

Le format DISCOUNTER est le principal point faible : les trois variantes le surestiment fortement, avec des MAPE comprises entre 198,5% et 255,0%. La Student-T nichée réduit l’erreur par rapport à Laplace et à la Student-T simple, mais l’écart reste trop important pour être interprété comme une simple variation de vraisemblance. Le diagnostic doit donc être mené au niveau magasin, car le problème vient probablement de la représentativité du format dans l’échantillon test et surtout de magasins très récents, plutôt que d’un choix entre Laplace et Student-T uniquement.

Globalement, la Student-T simple apparaît comme le meilleur compromis : elle améliore MARKET et PROXI, reste proche des meilleures performances sur HYPERCASH, et conserve une performance acceptable sur HYPER. La variante nichée est très bonne sur HYPER et améliore DISCOUNTER, mais elle ne domine pas les autres formats. Laplace n’est clairement préférable que sur HYPERCASH. Le choix de la Student-T pour la suite se justifie donc moins par une domination absolue que par sa robustesse moyenne et par sa capacité à réduire les erreurs sur les formats les plus opérationnels pour l’expansion courante.

5.2.2 Intervalles prédictifs

En plus des erreurs ponctuelles, un modèle bayésien doit être évalué sur la calibration de ses distributions prédictives. Le HDI (*Highest Density Interval*) à 94% est l’intervalle le plus court contenant 94% de la masse postérieure prédictive :

$$\Pr \left(y_i^{\text{obs}} \in \text{HDI}_{94\%}(y_i^{\text{rep}}) \right) \approx 0,94 \quad (5.7)$$

pour un modèle bien calibré. Cette métrique ne demande pas que chaque prédiction ponctuelle soit exacte, elle vérifie plutôt si l’incertitude annoncée est réaliste. Une couverture trop faible signifie que les intervalles sont trop étroits et que le modèle sous-estime le risque d’erreur sur de nouveaux magasins.




Figure 5.2 : Couverture empirique des intervalles HDI à 94% sur l’ensemble test. La ligne pointillée représente la couverture nominale.

La Figure 5.2 révèle une sous-couverture nette. La couverture globale reste inférieure à la cible nominale de 94% : elle atteint 25,0% pour Laplace, 43,8% pour Student-T et 62,5% pour Student-T nichée. Même lorsque la variante nichée élargit les intervalles et améliore la couverture, le modèle demeure insuffisamment calibré. Dans le vocabulaire de la calibration prédictive, le modèle est sous-dispersé : ses distributions prédictives conditionnelles sont trop étroites relativement aux observations laissées de côté.




Figure 5.3 : Biais relatif par format et par modèle. Les valeurs positives indiquent une surestimation, les valeurs négatives une sous-estimation.

La Figure 5.3 confirme que le changement de vraisemblance ne suffit pas à supprimer les biais. La vraisemblance Student-T améliore légèrement les métriques globales, mais les signes de biais restent les mêmes. Ce résultat est typique d'un contrôle prédictif utile : il montre que la défaillance ne se situe pas uniquement dans le traitement des résidus, mais dans la spécification de l'utilité ou dans les a priori par format.

La validation ne doit donc pas se limiter à l'erreur absolue. Dans ce contexte orienté vers l'aide à l'implantation, l'enjeu opérationnel consiste aussi à vérifier si le modèle classe correctement les magasins : un outil peut être utile pour prioriser les sites candidats même lorsque ses prédictions en valeur absolue restent imparfaitement calibrées.

5.2.3 Vérification de la cohérence ordinale par format

L'objectif central du projet n'est pas seulement de produire une estimation ponctuelle exacte du chiffre d'affaires, mais aussi de fournir un outil de hiérarchisation des sites candidats. Deux corrélations sont donc utilisées. La corrélation de Spearman compare les rangs observés et prédits :

$$\rho_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad (5.8)$$

où d_i est l'écart entre le rang observé et le rang prédit du magasin i . Une valeur proche de 1 signifie que le modèle classe correctement les magasins, même si les montants prédits ne sont pas parfaitement calibrés. La corrélation de Pearson en échelle logarithmique mesure plutôt l'alignement linéaire entre $\log(y_i)$ et $\log(\hat{y}_i)$:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(z_i - \bar{z})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (z_i - \bar{z})^2}}, \quad x_i = \log(y_i), z_i = \log(\hat{y}_i). \quad (5.9)$$

Elle complète Spearman en vérifiant si les écarts de niveau restent cohérents sur une échelle relative.

La Figure 5.4 donne une lecture visuelle de cette cohérence de rang avant le détail numérique du tableau.




Figure 5.4 : Corrélation de rang de Spearman entre revenu prédit et revenu observé, par format commercial et globalement, pour les trois variantes de vraisemblance.

Table 5.3 : Corrélation de rang (Spearman) et corrélation de Pearson en échelle logarithmique, par format et globalement (ensemble test, $n = 16$).

Modèle	Format	n	Spearman ρ	Pearson (log)
Nested Student	DISCOUNTER	2	-1,00	-1,00
Nested Student	HYPER	4	0,80	0,92
Nested Student	HYPERCASH	2	1,00	1,00
Nested Student	MARKET	4	0,80	0,33
Nested Student	PROXI	4	0,80	0,83
Nested Student	Tous	16	0,98	0,93
Laplace	DISCOUNTER	2	-1,00	-1,00
Laplace	HYPER	4	0,40	0,74
Laplace	HYPERCASH	2	1,00	1,00
Laplace	MARKET	4	0,60	0,34
Laplace	PROXI	4	0,80	0,67
Laplace	Tous	16	0,96	0,92
Student	DISCOUNTER	2	-1,00	-1,00
Student	HYPER	4	0,80	0,89
Student	HYPERCASH	2	1,00	1,00
Student	MARKET	4	0,80	0,60
Student	PROXI	4	0,80	0,89
Student	Tous	16	0,98	0,93

La lecture du Tableau 5.3 nuance les MAPE. Sur l'ensemble des seize magasins, la corrélation de rang dépasse 0,96 pour les trois modèles et atteint 0,98 pour les deux variantes Student-T : le modèle ordonne donc correctement les magasins, ce qui correspond directement à l'usage de présélection. Par format, la Student-T reste cohérente sur HYPER, MARKET et PROXI ($\rho = 0,80$). Le cas DISCOUNTER est un signal localisé : avec deux observations seulement, $\rho = -1$ indique surtout un problème de représentativité à examiner magasin par magasin.

5.3 Diagnostics structurels du modèle

5.3.1 Décomposition du diagnostic DISCOUNTER

Le format DISCOUNTER concentre le biais positif le plus important, avec une surestimation supérieure à +100% pour les trois variantes. L'analyse des deux magasins test montre que cette erreur est surtout liée à l'ancienneté des points de vente et à la manière dont la cible de revenu est construite. Le magasin 7415 est ouvert depuis environ 17,2 mois et observe déjà un chiffre d'affaires de 2,13 millions. Pour ce magasin, la Student-T simple prédit 1,56 million, soit une erreur contenue de -26,7%. Le magasin 7542, en revanche, n'a que 5,7 mois d'ancienneté et un chiffre d'affaires observé de 1,15 million. La même spécification lui attribue 6,35 millions, soit une erreur de +453,1%. Le diagnostic n'est donc

Table 5.4 : Deux magasins test expliquent l'instabilité du format DISCOUNTER.

Magasin	CA obs. MDH	Âge mois	Surface	Préd. Student MDH	Erreur
7415	2,128	17,2	150	1,559	-26,7%
7542	1,148	5,7	153	6,347	+453,1%

pas porté par les deux magasins de manière symétrique : le magasin 7415 réduit la MAPE moyenne du format, tandis que le magasin 7542 la détermine presque entièrement. Cette dissymétrie s'explique par le protocole d'apprentissage. Le modèle a principalement appris sur des magasins déjà installés, généralement ouverts depuis au moins douze mois, puis il est utilisé ici pour prédire un magasin de six mois. Or le paramètre de maturité b_{old} reste calibré à une échelle annuelle et ne corrige que faiblement le revenu prédit pour une ouverture récente. Le modèle prédit donc davantage un potentiel de magasin mature qu'un chiffre d'affaires réellement observé après quelques mois d'exploitation.

Le déplacement du panier moyen `base_pm` pour DISCOUNTER va dans le même sens. Lorsque le panier moyen postérieur s'éloigne fortement de son a priori économique ($\exp(3,0) \approx 20$), il peut devenir une variable de compensation : le modèle ajuste le niveau moyen du format pour expliquer des revenus annuels, mais il ne dispose pas d'une trajectoire mensuelle permettant de distinguer un magasin mature d'un magasin encore en montée en charge. Ce point n'invalidé pas le modèle pour la présélection, mais il limite sa capacité à prédire correctement des ouvertures très récentes.

5.3.2 Diagnostic a priori–a posteriori des paramètres structurels

Conformément à la démarche de flux de travail bayésien itératif décrite par [28], l'évaluation d'un modèle ne se limite pas à ses performances prédictives. Elle inclut un examen de ce que le modèle a appris, c'est-à-dire un déplacement entre la distribution a priori et la distribution a posteriori de chaque paramètre. Un paramètre dont la distribution a posteriori reste proche du a priori n'a pas été informé par les données, soit parce que les données sont peu informatives pour ce paramètre, soit parce que l'a priori était déjà bien spécifié. Un paramètre dont la distribution a posteriori se déplace fortement, ou dont la distribution a posteriori se situe dans une région a priori jugée peu plausible, signale une tension entre les hypothèses de départ et les données observées, et constitue une piste de révision pour l'itération suivante du modèle.

Les Figures 5.5 à 5.8 résument les déplacements a priori–a posteriori les plus utiles au diagnostic.




Figure 5.5 : Distribution a priori et a posteriori du coefficient d'accessibilité piétonne b_{walk} , par format commercial.




Figure 5.6 : Distribution a priori et a posteriori du coefficient d'accessibilité automobile b_{drive} , par format commercial.




Figure 5.7 : Distribution a priori et a posteriori du panier moyen $base_pm$, par format commercial.




Figure 5.8 : Distribution a priori et a posteriori du degré de liberté ν de la vraisemblance Student-T.

Deux lectures principales se dégagent de ces figures. Premièrement, le panier moyen $base_pm$ pour le format DISCOUNTER se déplace dans le sens discuté à la section précédente, ce qui confirme

l'hypothèse d'une compensation de spécification plutôt que d'une véritable information nouvelle sur le panier moyen réel. Deuxièmement, le degré de liberté ν de la vraisemblance Student-T se concentre autour de valeurs comprises entre cinq et six pour les deux variantes Student-T (Tableau 5.2). Une valeur de ν dans cette plage indique une vraisemblance aux queues nettement plus lourdes qu'une loi normale, mais pas extrêmement lourdes. Le modèle a donc appris qu'il existe des résidus atypiques (cohérent avec le cas DISCOUNTER), sans pour autant basculer vers un régime où la quasi-totalité de la masse de vraisemblance se trouve dans les queues.

5.4 Interprétation opérationnelle

Cette partie isole les résultats directement mobilisables par une équipe d'expansion. Après les diagnostics statistiques, l'objectif est de traduire les coefficients du modèle en règles de lecture géographique simples, sans les transformer en prévisions définitives.

Élasticités d'accessibilité

Table 5.5 : Effet estimé d'un doublement du temps d'accès (marche ou voiture) sur l'attractivité d'un magasin, par format, pour le modèle Student-T. La valeur est calculée comme $(\exp(-b \cdot \ln 2) - 1) \times 100$.

Format	Effet doublement marche (%)	Effet doublement voiture (%)
DISCOUNTER	-42,1	-6,6
PROXI	-56,6	-15,2
MARKET	-29,7	-32,2
HYPER	-10,3	-5,6
HYPERCASH	-4,1	-6,1

Le Tableau 5.5 traduit les coefficients b_{walk} et b_{drive} en une grandeur directement interprétable : la variation attendue de l'attractivité d'un magasin lorsque son temps d'accès double. Cette lecture est plus utile pour la décision que la valeur brute des coefficients, car elle permet de comparer les formats sur une même échelle opérationnelle.

Les résultats confirment une segmentation nette des formats. PROXI est le format le plus sensible à la marche : un doublement du temps piéton réduit l'attractivité estimée de 56,6%. DISCOUNTER présente également une forte pénalité à pied (-42,1%), mais une pénalité voiture limitée (-6,6%), ce qui suggère une dépendance forte à la micro-localisation immédiate. À l'inverse, HYPER et HYPERCASH sont peu pénalisés par l'éloignement piéton, respectivement -10,3% et -4,1%, ce qui est cohérent avec des formats de destination pour lesquels la taille de l'offre, le stationnement et le bassin de population compensent une distance plus élevée.

MARKET constitue un cas intermédiaire important. La pénalité voiture (-32,2%) y est du même ordre que la pénalité marche (-29,7%), ce qui indique que ce format est exposé simultanément à la concurrence de proximité et à l'accessibilité automobile locale. Pour l'expansion, cette lecture invite donc à ne pas appliquer une règle unique de distance : un site PROXI ou DISCOUNTER doit être évalué très finement à l'échelle de la rue ou du quartier, tandis qu'un site HYPER ou HYPERCASH doit être lu davantage à l'échelle du bassin de chalandise, de la visibilité routière et de la capacité de dépense agrégée.

5.5 Limites du modèle

Calibration de l'incertitude

Les résultats doivent être interprétés comme une première itération diagnostique et non comme un outil de prévision définitif. La limite la plus visible concerne la calibration : les intervalles HDI à 94% couvrent seulement 62,5% des magasins test pour la Student-T nichée, 43,8% pour la Student-T et 25,0% pour Laplace. Le modèle est donc sous-dispersé : il annonce une incertitude trop faible relativement aux erreurs observées hors échantillon. Dans un usage opérationnel, cela signifie que les prédictions ponctuelles ne doivent pas être lues comme des chiffres d'affaires garantis, mais comme des ordres de grandeur à comparer entre scénarios.

Taille et représentativité des données

Une deuxième limite vient directement des données disponibles. L'ensemble test ne contient que seize magasins et certains formats, notamment DISCOUNTER et HYPERCASH, ne comptent que deux observations. Les métriques par format sont donc très sensibles à un seul point atypique. Le cas DISCOUNTER l'illustre clairement : le magasin 7542, ouvert depuis seulement 5,7 mois, porte presque toute la MAPE du format. Avec si peu d'observations, il est difficile de distinguer ce qui relève d'un comportement structurel du format, d'une ouverture encore immature, d'une spécificité locale ou d'un bruit de mesure.

Granularité temporelle des revenus

La granularité temporelle constitue une troisième limite importante. Le modèle est estimé principalement sur des revenus annuels de magasins déjà stabilisés, puis il est évalué sur des magasins dont l'ancienneté peut être très différente. Il explique donc mal une ouverture récente observée après quelques mois seulement. Une extension naturelle serait d'intégrer des revenus mensuels ou trimestriels sous forme de panel, afin d'apprendre explicitement les courbes de montée en charge après ouverture. Cette amélioration permettrait de séparer deux objets aujourd'hui mélangés : le potentiel commercial mature d'un site et le chiffre d'affaires partiel observé pendant sa phase de lancement.

Identification des paramètres

Une quatrième limite concerne l'identification des paramètres. Plusieurs variables explicatives décrivent des dimensions proches du potentiel local : surface, population, capacité de dépense, accessibilité et format commercial. Sur un échantillon réduit, ces effets peuvent se compenser. Par exemple, un panier moyen par format peut absorber une partie d'un effet de maturité non modélisé, ou une variable d'accessibilité peut capter une partie de la qualité commerciale du site. Les coefficients ne doivent donc pas être interprétés comme des effets causaux isolés. Ils décrivent une structure de prédiction cohérente avec les données disponibles, mais leur identification reste partielle tant que le modèle ne dispose pas de davantage de variations indépendantes entre formats, zones, anciennetés et niveaux de concurrence.

Variables métier non observées

Enfin, plusieurs dimensions métier restent absentes ou approximées. Le modèle ne représente pas directement la visibilité commerciale, la qualité du parking, les flux réels de passage, l'intensité concurrentielle fine, les ruptures d'assortiment, les politiques prix, ni les campagnes locales. Les variables communales et les distances moyennes sont utiles pour construire une première base géospatiale homogène, mais elles restent trop agrégées pour expliquer toute la performance d'un magasin. Les prochaines itérations devraient donc enrichir les données à trois niveaux : davantage d'observations par format, une dimension temporelle mensuelle, et des variables locales plus fines sur l'environnement commercial immédiat.

Conclusion

Ce chapitre montre que le modèle constitue une première itération utile mais non finale, conformément au flux de travail bayésien de [gelman2020bayesian](#) : les diagnostics servent autant à mesurer la performance actuelle qu'à définir l'itération suivante. La Student-T simple apparaît comme le meilleur compromis actuel entre robustesse, parcimonie et performance, tandis que la variante nichée ne justifie pas encore une complexification complète. Les erreurs absolues, la sous-couverture des intervalles et les difficultés d'identification imposent une lecture prudente des chiffres d'affaires prédits.

La valeur ajoutée du projet réside donc moins dans une prévision définitive que dans la mise en place d'un cadre de décision structuré. Le modèle classe correctement les magasins, rend interprétables les effets d'accessibilité, identifie les formats problématiques et transforme les erreurs en pistes concrètes d'amélioration des données. Les priorités sont désormais claires : mieux calibrer l'incertitude, enrichir les formats rares, intégrer une dimension temporelle mensuelle et ajouter des variables locales plus proches de la réalité commerciale des sites. À ce stade, le modèle doit être utilisé comme un outil de diagnostic, de présélection et de comparaison prudente de scénarios.

Conclusion Générale et Perspectives

Ce projet de fin d'études s'inscrit dans une problématique stratégique pour Label'Vie : mieux évaluer le potentiel des nouvelles implantations commerciales à partir de données réelles, géospatiales et opérationnelles. L'enjeu n'était pas de remplacer l'expertise métier par une prédiction automatique du chiffre d'affaires, mais de construire un cadre d'aide à la décision capable de comparer des localisations, d'objectiver les facteurs territoriaux et de quantifier l'incertitude associée à chaque scénario d'ouverture.

Le travail réalisé a permis de mettre en place une chaîne complète allant de la constitution d'une base de données géospatiale à la modélisation bayésienne du potentiel commercial. L'exploitation de données issues du système d'information de l'entreprise, enrichies par des sources territoriales complémentaires, a permis d'aborder une problématique concrète d'aide à la décision en matière d'implantation commerciale. Cette démarche a également mis en évidence plusieurs enjeux propres aux projets de valorisation de données : hétérogénéité des formats, qualité variable des sources, disponibilité partielle de certaines informations, différences de maturité entre les magasins et complexité des comportements de consommation. Malgré ces contraintes, les travaux menés montrent qu'il est possible de structurer, intégrer et exploiter ces données afin de produire des indicateurs et des estimations utiles à l'évaluation du potentiel commercial d'un emplacement.

L'apport principal du projet réside dans la mise en cohérence de ces données et dans leur traduction en un outil probabiliste d'aide à l'implantation. Le cadre bayésien retenu est particulièrement adapté à ce type de problème, car le chiffre d'affaires d'un magasin dépend de nombreux facteurs observables et non observables : population adressable, accessibilité, concurrence, format, positionnement prix, habitudes locales, dynamique commerciale et effets opérationnels. Plutôt que de produire uniquement une valeur prédite, le modèle fournit une distribution de résultats plausibles, ce qui permet d'intégrer explicitement le risque dans l'analyse.

Les résultats obtenus montrent que la prédiction exacte du chiffre d'affaires reste difficile, notamment en raison du volume limité de données et de la forte hétérogénéité des points de vente. Cette limite est importante, mais elle ne réduit pas l'intérêt opérationnel du modèle. Dans un contexte d'expansion, la valeur d'un tel outil réside surtout dans sa capacité à préserver l'ordre relatif des magasins, à distinguer les sites prometteurs des sites plus risqués et à comparer plusieurs scénarios sur une base homogène. Le modèle constitue ainsi un support pertinent pour la présélection d'emplacements, la priorisation des études terrain et l'éclairage des décisions d'investissement.

Le projet met également en évidence plusieurs limites structurelles. Certaines dimensions déterminantes de la performance commerciale restent imparfaitement observées, notamment les politiques de prix locales, les actions promotionnelles, les flux de mobilité fins, la visibilité réelle du site, la ma-

turité commerciale des magasins ou encore l'intensité concurrentielle exacte. L'utilisation de données principalement annuelles limite aussi la compréhension des trajectoires de montée en charge. Enfin, la calibration des données de population, d'occupation du sol et de concurrence peut encore être affinée afin de mieux représenter la demande réellement accessible.

Ces limites ouvrent des perspectives d'amélioration naturelles. L'intégration de données mensuelles permettrait de passer vers une logique de panel, capable de suivre l'évolution des magasins dans le temps, de modéliser la saisonnalité et de distinguer plus clairement potentiel structurel et performance observée. L'enrichissement des variables métier, notamment par des informations plus fines sur le pricing, les promotions, les formats, les assortiments et les concurrents, renforcerait également la qualité de la vraisemblance. Lorsque des chiffres d'affaires déclarés ou estimés des enseignes concurrentes sont accessibles, ils pourraient être intégrés au modèle afin de mieux représenter l'attractivité relative des alternatives commerciales. À défaut, des approches indirectes fondées sur des sources publiques, du scraping encadré, des enquêtes terrain ou des indicateurs de présence numérique pourraient compléter la connaissance du marché, en particulier pour le commerce traditionnel.

D'autres améliorations concernent la représentation du territoire. Une meilleure calibration de la population, de la densité de ménages, du pouvoir d'achat local, de l'occupation du sol résidentielle et des temps d'accès réels permettrait de construire des bassins de chalandise plus proches de la réalité. Sur le plan méthodologique, l'utilisation de méthodes MCMC, notamment NUTS, éventuellement accélérées par GPU lorsque le coût de calcul le justifie, offrirait une exploration plus fidèle de la distribution a posteriori que des approximations plus simples, en particulier lorsque l'incertitude présente des formes non gaussiennes.

À terme, ce travail peut servir de socle à une solution opérationnelle permettant de simuler un grand nombre de sites candidats à l'échelle du Royaume, de générer pour chacun une distribution a posteriori du chiffre d'affaires potentiel, puis de les classer selon différents critères : revenu attendu, risque de sous-performance, probabilité de dépasser un seuil, cannibalisation possible ou complémentarité avec le réseau existant. Une telle solution, intégrée à des outils de visualisation géographique et décisionnelle, fournirait aux équipes de *Market Intelligence*, d'expansion, de stratégie et de finance un cadre commun pour comparer les opportunités de manière plus robuste et plus transparente.

En définitive, ce projet démontre la faisabilité d'un cadre bayésien d'aide à la décision pour l'évaluation des implantations commerciales de Label'Vie. Sa contribution principale ne réside pas dans la promesse d'une prévision parfaite, mais dans la structuration des données, la formalisation de l'incertitude et la capacité à transformer un problème d'expansion complexe en un processus analytique exploitable. Il constitue ainsi une base solide pour une solution plus dynamique, mieux calibrée et progressivement intégrable aux décisions stratégiques d'implantation à l'échelle nationale.

Bibliographie

- [1] David R. Bell, Teck-Hua Ho, and Christopher S. Tang. Determining where to shop : Fixed and variable costs of shopping. *Journal of Marketing Research*, 35(3) :352–369, 1998.
- [2] William J. Reilly. *The Law of Retail Gravitation*. W.J. Reilly, New York, 1931. Also known as Reilly’s law of retail gravitation. Often cited as Reilly (1929, 1931).
- [3] David L. Huff. Defining and estimating a trading area. *Journal of Marketing*, 28(3) :34–38, 1964.
- [4] Daniel McFadden. Conditional logit analysis of qualitative choice behavior. In Paul Zarembka, editor, *Frontiers in Econometrics*, pages 105–142. Academic Press, New York, 1974.
- [5] Daniel McFadden. Economic choices. *American Economic Review*, 91(3) :351–378, 2001.
- [6] Jacob Marschak. Binary choice constraints on random utility indicators. In Ingram Olkin, Sudhish G. Ghurye, Wassily Hoeffding, William G. Madow, and Henry B. Mann, editors, *Contributions to Probability and Statistics*, pages 97–132. Stanford University Press, Stanford, CA, 1960.
- [7] Kenneth E. Train. *Discrete Choice Methods with Simulation*. Cambridge University Press, Cambridge ; New York, 2 edition, 2009.
- [8] R. Duncan Luce. *Individual Choice Behavior : A Theoretical Analysis*. Wiley, New York, 1959.
- [9] Daniel McFadden. Modelling the choice of residential location. In A. Karlqvist, L. Lundqvist, F. Snickars, and J. W. Weibull, editors, *Spatial Interaction Theory and Planning Models*, pages 75–96. North-Holland, Amsterdam, 1978.
- [10] Andrew Gelman, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari, and Donald B. Rubin. *Bayesian Data Analysis*. CRC Press, Boca Raton, 3 edition, 2013.
- [11] Richard H. Byrd, Peihuang Lu, Jorge Nocedal, and Ciyu Zhu. A limited memory algorithm for bound constrained optimization. *SIAM Journal on Scientific Computing*, 16(5) :1190–1208, 1995.
- [12] David M. Blei, Alp Kucukelbir, and Jon D. McAuliffe. Variational inference : A review for statisticians. *Journal of the American Statistical Association*, 112(518) :859–877, 2017.
- [13] Alp Kucukelbir, Dustin Tran, Rajesh Ranganath, Andrew Gelman, and David M. Blei. Automatic differentiation variational inference. *Journal of Machine Learning Research*, 18(14) :1–45, 2017.
- [14] Atılım Gunes Baydin, Barak A. Pearlmutter, Alexey Andreyevich Radul, and Jeffrey Mark Siskind. Automatic differentiation in machine learning : A survey. *Journal of Machine Learning Research*, 18(153) :1–43, 2018.

-
- [15] Oriol Abril-Pla, Virgile Andreani, Colin Carroll, Larry Dong, Christopher J. Fonnesbeck, Max Kochurov, Ravin Kumar, Junpeng Lao, Christian C. Luhmann, Osvaldo A. Martin, Michael Osthege, and Ricardo Vieira. PyMC : A modern, and comprehensive probabilistic programming framework in python. *PeerJ Computer Science*, 9 :e1516, 2023.
- [16] Haut-Commissariat au Plan. Haut-commissariat au plan (hcp) – morocco. <https://www.hcp.ma>, 2025. Official statistical agency of Morocco ; census data, demographic surveys.
- [17] Google Maps Platform. Places api. <https://developers.google.com/maps/documentation/places/web-service/>, 2025. Programmatic access to Google’s global database of businesses and POIs.
- [18] OpenStreetMap Foundation. Openstreetmap (osm). <https://www.openstreetmap.org>, 2025. Collaborative free geographic database ; road networks, POIs, building footprints.
- [19] Project OSRM. Open source routing machine (osrm) – c++ backend. <https://github.com/project-osrm/osrm-backend>, 2025. High-performance routing engine for OpenStreetMap data ; HTTP API, car/bike/walk profiles.
- [20] Marcello Schiavina, Sergio Freire, Alessandra Carioli, and Kytt MacManus. Ghs-pop r2023a – ghs population grid multitemporal (1975-2030), 2023. GHS-POP grid, 100m resolution, used for population distribution.
- [21] IOGP Geomatics Committee. Wgs 84 / utm zone 29n (epsg :32629). <https://epsg.io/32629>, 2025. Projected coordinate system for Morocco ; metric units, UTM 29N.
- [22] Meta AI. Segment anything model 3 (sam 3) : Promptable concept segmentation. <https://ai.meta.com/blog/segment-anything-model-3/>, 2025. Released 2025-11-19. Zero-shot foundation model for image/video segmentation.
- [23] Esri. World imagery basemap. <https://www.esri.com/arcgis-blog/products/arcgis-living-atlas/imagery/whats-new-in-world-imagery-july-2025/>, 2025. High-resolution satellite imagery, refreshed monthly, Maxar Vivid product line.
- [24] TomTom. Traffic stats api. <https://developer.tomtom.com/traffic-stats/documentation/product-information/introduction>, 2025. Historical traffic data : average speed, travel time, sample size ; Floating Car Data (FCD).
- [25] Apache Software Foundation. Apache parquet. <https://parquet.apache.org>, 2025. Column-oriented data file format ; high compression (Snappy/Zstd), efficient column pruning.
- [26] Google. Snappy : A fast compressor/decompressor. <https://github.com/google/snappy>, 2025. Low-CPU-overhead compression ; used in Parquet, Bigtable, etc.
- [27] Yann Collet. Zstandard (zstd) real-time compression algorithm. <https://facebook.github.io/zstd/>, 2025. High-compression ratio with configurable speed ; used in Parquet, MongoDB, etc.
- [28] Andrew Gelman, Aki Vehtari, Daniel Simpson, Charles C. Margossian, Bob Carpenter, Yuling Yao, Lauren Kennedy, Jonah Gabry, Paul-Christian Bürkner, and Martin Modrák. Bayesian workflow. *arXiv preprint arXiv :2011.01808*, 2020.

Annexe – Dépôts, données et reproductibilité

L'ensemble des artefacts techniques associés à ce projet est mis à disposition publiquement afin d'assurer la reproductibilité complète de la chaîne de traitement, de l'acquisition des données jusqu'à l'inférence bayésienne.

Dépôt principal

Le dépôt `retail_choice_location`, disponible à l'adresse https://github.com/TFerhan/retail_choice_location_model, constitue le support opérationnel du projet dans son intégralité. Il regroupe :

- les scripts de collecte, de nettoyage et d'harmonisation des données géospatiales, commerciales et socio-démographiques ;
- la construction de la couche analytique et la préparation des variables explicatives du modèle ;
- l'implémentation du modèle structurel bayésien sous PyMC, incluant la spécification des distributions a priori, les variantes de vraisemblance et les routines d'inférence ;
- les scripts de diagnostic, d'évaluation prédictive et de production des figures utilisées dans le manuscrit.

Outil de calcul des distances entre grilles et magasins via OSRM

Le dépôt `osrm_tool`, disponible à l'adresse https://github.com/TFerhan/osrm_tool, isole le module de routage géospatial. Il automatise le calcul des temps de trajet piéton et automobile entre chaque couple grille–magasin via OSRM sur le réseau OpenStreetMap, et produit les mesures d'accessibilité utilisées dans la spécification de l'utilité V_{gs} .

Polygones géoréférencés des bâtiments au Maroc

Le jeu de données `Buildings_mask_morocco`, publié sur Hugging Face à l'adresse https://huggingface.co/datasets/tferhan/Buildings_mask_morocco, met à disposition les polygones géoréférencés issus de la segmentation sémantique des bâtiments au Maroc. Ces masques enrichissent la lecture spatiale de la grille GHS-POP et permettent de contrôler la cohérence des cellules de population dans les zones urbaines et périurbaines.
